计算机科学与探索
Journal of Frontiers of Computer Science and Technology
1673-9418/2025/19(01)-0045-20
doi: 10.3778/j.issn.1673-9418.2403070

基于Transformer模型的时序数据预测方法综述

孟祥福+,石皓源
辽宁工程技术大学 电子与信息工程学院,辽宁 葫芦岛 125105
+ 通信作者 E-mail: marxi@126.com

摘　要:时序数据预测(TSF)是指通过分析历史数据的趋势性、季节性等潜在信息,预测未来时间点或时间段的数值和趋势。时序数据由传感器生成,在金融、医疗、能源、交通、气象等众多领域都发挥着重要作用。随着物联网传感器的发展,海量的时序数据难以使用传统的机器学习解决,而Transformer在自然语言处理和计算机视觉等领域的诸多任务表现优秀,学者们利用Transformer模型有效捕获长期依赖关系,使得时序数据预测任务取得了飞速发展。综述了基于Transformer模型的时序数据预测方法,按时间梳理了时序数据预测的发展进程,系统介绍了时序数据预处理过程和方法,介绍了常用的时序预测评价指标和数据集。以算法框架为研究内容系统阐述了基于Transformer的各类模型在TSF任务中的应用方法和工作原理。通过实验对比了各个模型的性能、优点和局限性,并对实验结果展开了分析与讨论。结合Transformer模型在时序数据预测任务中现有工作存在的挑战提出了该方向未来发展趋势。
关键词:深度学习;时序数据预测;数据预处理;Transformer模型
文献标志码:A　　**中图分类号:**TP391

Survey of Transformer-Based Model for Time Series Forecasting

MENG Xiangfu+, SHI Haoyuan
School of Electronic and Information Engineering, Liaoning Technical University, Huludao, Liaoning 125105, China

Abstract: Time series forecasting (TSF) refers to predicting future values and trends at specific time points or over time periods by analyzing potential information such as trends and seasonality in historical data. Time series data, generated by sensors, play a significant role in numerous fields, including finance, healthcare, energy, transportation, and meteorology. With the development of IoT sensors, the massive amounts of time series data are difficult to handle using traditional machine learning techniques. However, the Transformer model, which has shown excellent performance in various tasks within natural language processing and computer vision, has been effectively utilized by researchers to capture long-term dependencies, leading to rapid advancements in time series forecasting tasks. Therefore, this paper reviews time series forecasting methods based on the Transformer model. It chronologically outlines the development process of time series forecasting, systematically introduces the preprocessing procedures and methods for time series data, and presents commonly used evaluation metrics and datasets for time series forecasting. By focusing on algorithm frameworks, this paper systematically explains the application methods and working principles of various models based on the Transformer in TSF tasks. Through experiments, it compares the performance, advantages, and limitations of different models, and analyzes the experimental results. Finally, considering the challenges present in current work on Transformer models for time series forecasting, this paper proposes future development trends in this direction.
Key words: deep learning; time series forecasting; data preprocessing; Transformer

基金项目:国家自然科学基金(61772249)。
This work was supported by the National Natural Science Foundation of China (61772249).
收稿日期:2024-03-26　　**修回日期:**2024-07-19

中国知网 https://www.cnki.net

金融、医疗、能源、交通、气象等众多领域都存在时序数据，时序数据广泛存在且容易获取。但随着传感设备的普及和数据处理技术发展，时序数据正以爆炸式速度生成[1-2]，对时序数据的分析有重大意义。通过对时序数据分析可提取有价值信息，例如气象降雨预报[3-6]、交通流量预测[7-11]、金融分析[12-18]、流感趋势监测[19-22]、医学药物反应[23-25]、各类系统运作负荷[26-28]等。

时序数据预测任务面临的最主要挑战是处理长序列和计算效率问题[29-31]。传统基于统计的时序预测模型如支持向量机（support vector machine，SVM）和自回归模型（autoregressive model，AR）等需要手动设置季节性、趋势项等专业时间模式[32]，难以对大规模数据进行高效精准处理[33]。为此，神经网络方法被提出解决上述挑战，其中循环神经网络（recurrent neural network，RNN）依靠独特的顺序结构能够有效处理时序预测问题[34]，然而梯度消失和梯度爆炸问题使RNN难以训练，尽管出现了长短期记忆循环神经网络（long short-term memory，LSTM）[35]、门控循环单元（gated recurrent unit，GRU）[36]等变体，但这些问题仍是挑战，限制了它们的性能。卷积神经网络（convolutional neural networks，CNN）凭借出色的特征提取能力，在时序预测任务中具有潜力[37]，但仅通过CNN解决时序预测任务是不充分的，因此通常将其作为一个功能模块，通过卷积操作提取局部特征提高模型预测性能。多层感知机（multi-layer perceptron，MLP）通过多个堆叠的隐藏层学习时序数据复杂的非线性关系并挖掘潜在规律[38]，但其建模能力有限，难以分析时序数据复杂的时间模式。

近年来Transformer在自然语言处理和图像领域取得了成功[39]，Transformer依靠强大的自注意力机制，解决了传统模型处理长序列时出现的效率低下、梯度爆炸和并行问题。Transformer依靠自注意力机制捕捉序列长距离依赖关系，具有更好的时序建模能力，处理时序数据有很大优势[40]，因此基于Transformer的研究工作逐渐增多。

时序数据预测作为时序数据分析的重要任务之一，旨在通过分析历史数据趋势性和季节性等潜在信息，预测未来时间点或时间段的数值和趋势。根据不同维度变量，可将时序数据预测分为单变量预测和多变量预测。根据预测不同时间跨度，可归纳为近期预测、短期预测、中期预测和长期预测。

有研究者对现有工作进行了综述[41]，但缺乏对基于Transformer的时序预测最新研究成果的介绍和实验效果对比。本文将详细综述时序数据预测的处理过程和方法，分别从时序数据预处理、时序预测评价指标和数据集、基于Transformer的时序预测方法以及未来展望几个方面进行详细阐述。基于Transformer的时序预测模型发展脉络如图1所示。

1 时序数据预处理

尽管传感器技术和网络飞速发展，但在获取真实时序数据时，由于人为失误或设备故障等原因，仍存在大量缺失值、噪声等异常[42-43]，脏数据使算法模型难以训练[44-45]。因此时序数据预处理是必要过程。

时序数据预处理旨在对各种脏数据进行处理，得到

图1 基于Transformer的时序预测模型发展脉络图

Fig.1 Development context of time series prediction model based on Transformer

中国知网 https://www.cnki.net

干净、标准和连续的数据，达到数据质量评价指标，提供给数据挖掘和数据预测等任务使用[46-49]。时序数据预处理的主要步骤分为时序数据清洗、时序数据整合、时序数据归约和时序数据变换，以此形成可用的时序数据集[50]。

1.1 时序数据清洗

时序数据清洗的目的是解决缺失、异常和噪声造成的数据不准确和不一致问题[51-52]，原始时序数据中的异常具有误导性，会妨碍信息提取并导致时序预测结果出现偏差，因此需要在时序数据预处理阶段解决这些异常。例如曹勇等人[53]根据数据相关性补全后，结合改进的模糊C-均值聚类完成物联网时序大数据异常检测；韩京宇等人[54]提出一种基于异常体征模式的清洗弱标签心电数据方法，实现心脏异常监测。

1.2 时序数据集成

时序数据集成是将多个传感器中的时序数据合并存放在同一个数据存储的过程[55-57]。由于行业繁多，获取到时序数据是多源且无序的，时序数据集成是必要过程。例如陈超等人[58]提出了基于时空聚类的多源异构时序数据集成方法，将时序不同步的混乱数据进行协调处理，同步后通过时空集合标定、时空聚类矩阵和集成函数实现时序数据集成；Markert等人[59]利用光学和合成孔径雷达传感器融合生成地表水时间序列，用于地表水动态监测。

1.3 时序数据归约

由于在海量时序数据上进行数据分析会造成不必要消耗，需要时序数据归约降低数据规模，在保证有用信息不减少情况下，尽可能减少数据分析量，而又不影响分析结果[60-61]。例如崔振等人[62]提出了离散余弦变换进行维归约，刘洪波等人[63]采用基于Shap方法对风电功率特征变量进行了可解释降维分析。

1.4 时序数据变换

时序数据变换的作用是将时序数据变换成适合分析的形式[64]，其中最主要的是非平稳时间序列变换。例如Ogasawara等人[65]提出一种自适应归一化，将时间序列转换为数据序列并计算全局统计属性，专门用于非平稳时间序列。

2 时序数据预测模型的评价指标与数据集

2.1 时序预测评价指标

评价指标是用于评估和分析时序数据预测模型性能的一种度量方法，是衡量模型性能的关键标准。常用的时序预测评价指标包括如下几个：

均方误差（mean squared error，MSE）[66]，是预测值与实际值之间差异平方的均值，反映预测值与实际值之间的总体误差，计算方法如式（1）所示：

$$\mathrm{MSE}(y,\hat{y}) = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \tag{1}$$

均方根误差（root mean squared error，RMSE）[67]，是均方误差的平方根，它对较大误差赋予更高权重，更加注重预测结果的稳定性，计算方法如式（2）所示：

$$\mathrm{RMSE}(y,\hat{y}) = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{2}$$

平均绝对误差（mean absolute error，MAE）[68]，是预测值与实际值之间绝对差异的平均值，使其不会受到离群值影响，计算方法如式（3）所示：

$$\mathrm{MAE}(y,\hat{y}) = \frac{1}{n}\sum_{i=1}^{n}(|y_i - \hat{y}_i|) \tag{3}$$

平均绝对百分比误差（mean absolute percentage error，MAPE）[69]，是预测值与实际值之间绝对值与实际值比值的平均值，考虑了实际值大小，避免了正负误差相互抵消，计算方法如式（4）所示：

$$\mathrm{MAPE}(y,\hat{y}) = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{y_i - \hat{y}_i}{y_i}\right| \times 100\% \tag{4}$$

对称平均绝对百分比误差（symmetric mean absolute percentage error，SMAPE）[70]，是对MAPE问题的修正指标，能较好避免MAPE因为真实值小而计算结果太大的问题，计算方法如式（5）所示：

$$\mathrm{SMAPE}(y_i,\hat{y}_i) = \frac{1}{n}\sum_{i=1}^{n}\frac{|y_i - \hat{y}_i|}{(|y_i| + |\hat{y}_i|)/2} \times 100\% \tag{5}$$

决定系数R^2[71-72]：也叫拟合优度，将可解释部分方差除以总方差，反映了自变量对因变量的可解释程度，以此评估模型可解释性，计算方法如式（6）所示：

$$R^2(y,\hat{y}) = 1 - \frac{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\frac{1}{n}\sum_{i=1}^{n}(y_i - \bar{y}_i)^2} = 1 - \frac{MSE}{Var} \tag{6}$$

式（1）~（6）中，y为真实值，$\hat{y}$为预测值，$\bar{y}$为y的均值，Var为方差。

除R^2以外，上述评价指标都是值越小越好。使用哪种评价指标取决于具体情况，通常会采用多种指标配合使用的方式，综合考虑有利于更深入分析模型。由于循环神经网络模型和Transformer模型在处理时序数据时的特性和应用重点有所不同，导致研究人员在评价算法性能时关注的指标也有所变化。

循环神经网络模型在处理时序数据时，由于其具有记忆能力，能更好捕捉时间序列中的长期依赖关系，在评价指标上更加关注对时间序列整体结构的建模能力，以及对不同任务的适应性。因此研究人员可能会采用

中国知网 https://www.cnki.net

多元化的评价指标来全面评估算法性能。

Transformer模型在处理时序数据时，由于其自注意力机制可并行计算，更加高效，在评价指标上更加注重预测准确性，即更加注重对未来值的预测能力。因此研究人员更多使用MAE和MSE衡量算法性能。

2.2 时序预测数据集

对于Transformer模型，使用高质量的数据对于模型训练、泛化能力和性能评估至关重要。表1给出6个真实基准数据集，描述了6个数据集的基本信息。它们涵盖了5个主流的时序数据预测应用领域：能源、交通、经济、天气和疾病。

表1 6个公共时序数据集的基本信息

Table 1 Basic information of 6 common time series datasets

数据集	变量数	采样频率	数据量
ETT	7	1 min	1 051 200
Electricity	321	1 h	26 304
Traffic	862	1 h	17 544
Exchange	8	1 d	7 588
Weather	21	10 min	52 696
ILI	7	1周	966

ETT（electricity transformer temperature）：电力变压器油温数据集，由国家电网提供，来自2016—2018年中国同一个省两个不同县电力变压器的每分钟记录，每个数据集包含1 051 200个数据点。由于数据量庞大，同时为探索长时预测的粒度问题，创建了不同子集。按15 min和1 h的采集频率划分为4个子数据集ETTm1、ETTm2、ETTh1和ETTh2，分别包含69 680和17 420条数据。每个数据点均包含7维特征，包括预测目标油温和6个不同类型的功率负载特征。

ECL（electricity consuming load）：电力消耗数据集，记录了2012—2014年321位客户的每小时用电量。

Traffic：交通数据集，由加州运输部提供，描述了2015—2016年旧金山高速公路862个传感器记录的每小时道路占用率。

Exchange：汇率数据集，记录了1990—2016年8个不同国家之间的每日汇率。

Weather：天气数据集，由马普生物地球化学研究所气象站提供，记录了2020—2021年每10 min采集的气压、气温和湿度等21个气象指标。

ILI：流感数据集，由美国疾病控制与预防中心提供，记录了2002—2021年每周的流感样疾病患者与患者总数的比例。

由于ETT数据集数据量庞大且其他数据集采样频率较长，本文选用细粒度子数据集ETTm2进行分析。以上数据集的可视化如图2所示，其中横轴为时间，纵

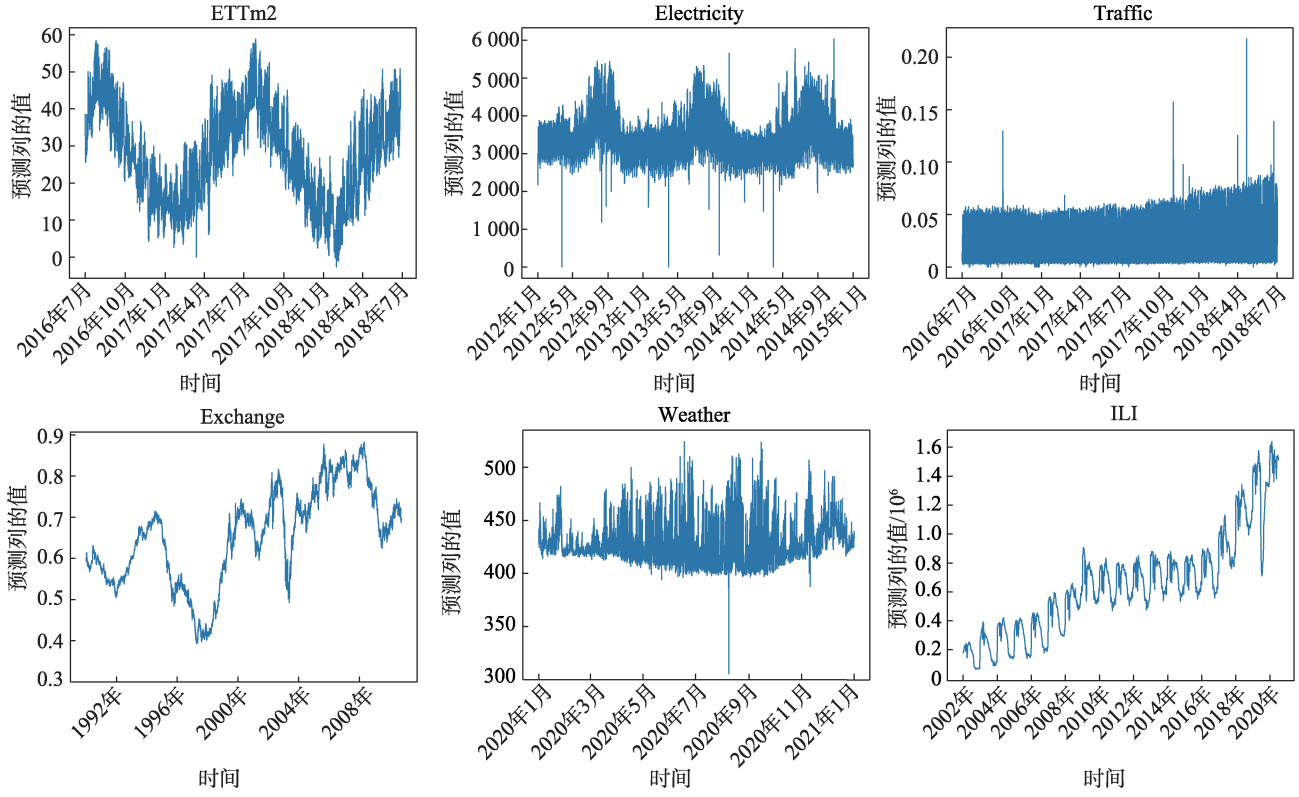

图2 6种数据集的可视化展示

Fig.2 Visualization of 6 datasets

中国知网 https://www.cnki.net

轴为预测列的值。

通过图2观察分析，ETTm2、Electricity、Traffic和Weather数据集具有较强的周期性和季节性，而Exchange数据集表现出较高随机性，没有明显的周期性和季节性；ILI数据集表现出明显的季节性而缺乏周期性。

3 基于Transformer的时序预测模型

Transformer依靠其出色的自注意力机制能够捕获长期依赖关系，解决了传统RNN模型无法支持长时预测和并行计算的问题，在时序数据预测任务中取得了优秀成绩。

自注意力机制的基本思想来自人类视觉系统工作原理。在处理复杂场景时，人类视觉系统会自动将注意力集中在与当前任务最相关的部分，而忽视其他不太相关的细节。这种选择性的关注能力能高效地从大量信息中提取关键信息[73-74]，其核心思想是权重分配。在自注意力机制中，每个元素都与所有元素进行比较，计算注意力得分，进而得到最终输出，计算方法如式(7)所示：

$$\mathrm{Attention}(\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V}) = \mathrm{softmax}\left(\frac{\boldsymbol{Q}\boldsymbol{K}^{\mathrm{T}}}{\sqrt{d_k}}\right)\boldsymbol{V} \tag{7}$$

其中，$\boldsymbol{Q} \in \mathbf{R}^{L_q \times d}$，$\boldsymbol{K} \in \mathbf{R}^{L_k \times d}$，$\boldsymbol{V} \in \mathbf{R}^{L_v \times d}$，$d$表示向量维度。$\boldsymbol{Q},\boldsymbol{K},\boldsymbol{V}$由输入矩阵$\boldsymbol{X}$线性变换而来，首先$\boldsymbol{Q}$与$\boldsymbol{KT}$进行点积运算，本质是$\boldsymbol{Q}$在$\boldsymbol{K}$上的投影，反映了$\boldsymbol{Q}$和$\boldsymbol{K}$的相似度。然后将结果除以$\sqrt{d_k}$，是为了防止$\boldsymbol{Q}\boldsymbol{K}^{\mathrm{T}}$过大，同时使其满足期望为0、方差为1的分布。接着进行softmax归一化，得到总和为1的权重系数。最后与$\boldsymbol{V}$点乘，得到加权值，输出为加权值之和。这样输入序列经过自注意力机制分配权重，输出加权后结果。

2017年，Vaswani等人[39]提出了全新编码器-解码器模型Transformer（如图3所示）。编码器和解码器由N个相同层堆叠而来，每层编码器由多头注意力模块和全连接前馈网络组成，同时引入残差连接和标准化来防止模型退化并提高收敛速度。每层解码器在此基础上插入一个多头注意力模块，对编码器的输出进行自注意力操作。

Transformer的核心部分自注意力模块，可看作一个能够动态更新权重的全连接层。由于参数量少，设计了多头注意力学习更丰富信息。自注意力模块并没有RNN那样捕获时间顺序信息的能力，因此在输入时嵌入位置编码添加位置信息，使用不同频率的正弦和余弦函数，计算方法如式(8)所示：

$$\mathrm{PE}(t)_i = \begin{cases} \sin\dfrac{t}{10\,000^{2k/d}}, i = 2k \\ \cos\dfrac{t}{10\,000^{2k/d}}, i = 2k+1 \end{cases} \tag{8}$$

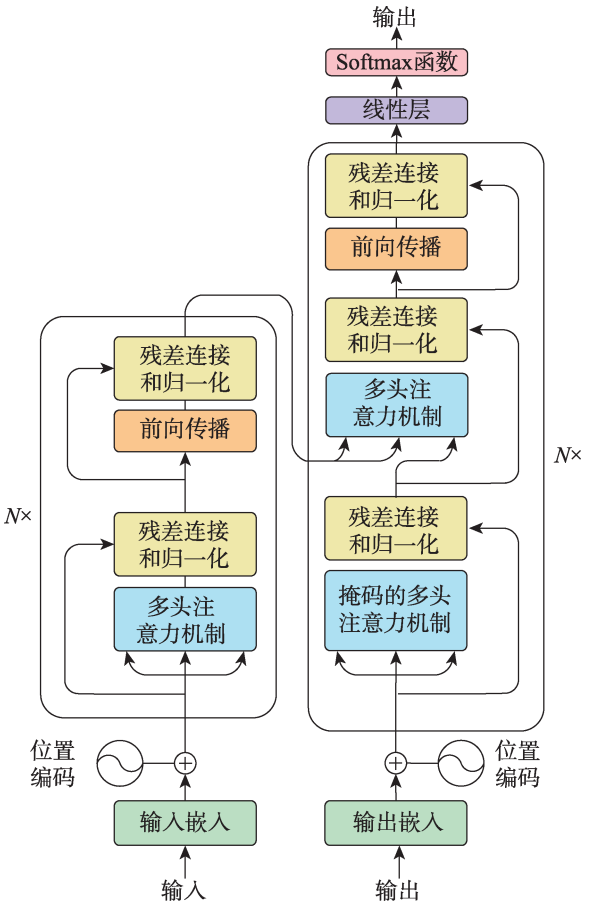

图3 Transformer结构示意图

Fig.3 Schematic diagram of Transformer structure

其中，t是在序列中的位置，d是向量维度，k是用于索引的自然数。通过正弦和余弦函数，把每个位置映射到唯一频率，使用相应正弦、余弦函数将该频率转换为嵌入向量中的一个元素，模型就可在处理输入序列时捕获到位置信息。

传统RNN类模型只能依靠上个时刻信息推测出下个时刻信息，使得模型无法处理长时序列。改进后的LSTM、GRU模型，也无法避免梯度爆炸等问题。Transformer采用了自注意力机制实现高效并行计算，使其最长路径仅为1，同时能够捕捉长期依赖关系，在时序数据预测任务中取得了优异性能。

3.1 时序预测Transformer模型分类

总结了现有基于Transformer的时序预测模型，从网络结构修改角度对Transformer类模型进行分类，从位置编码、注意力模块、模型结构和通用框架四个方面对近期先进的Transformer模型进行划分，更多模型细节将在后文讨论。

3.1.1 位置编码

时序性是时间序列数据重要特征，如何获取时间序

中国知网 https://www.cnki.net

列中位置信息是一项挑战。Transformer通过位置编码将位置信息嵌入到输入词向量中，使得Transformer模型保留时间序列的位置信息，常见位置编码可分为三类。

（1）传统位置编码。如式（8）所示，例如Song等人[75]利用传统位置编码开发了用于处理临床时序数据的注意力预测模型。虽然该方法可以从时间序列中提取部分位置信息，但无法捕获全局信息，不能充分利用时序数据的重要特征。

（2）可学习位置编码。针对传统编码器存在的挑战，一些研究如BERT（bidirectional encoder representations from transformers）模型采用了可学习位置编码，通过训练从时间序列中学习位置嵌入。例如Jin等人[76]提出用于交通流量预测的TrafficBERT模型。此外Zerveas等人[77]发现相较于确定性的正弦编码，使用可学习位置编码会有更好的性能；Li等人[78]在LogSparse Transformer中使用了可学习位置嵌入代替传统位置编码。

（3）时间戳编码。在长序列时序预测（long sequence time-series forecasting，LSTF）任务中，捕获长期依赖需要全局信息，时间戳通常蕴含丰富信息，如层次时间戳（日、周、月和年）和特殊时间戳（假期、事件）。但这些时间戳信息在传统位置编码难以利用，导致预测性能退化。为了应对这一挑战，Zhou等人[79]将时间戳引入了Transformer模型，提出了局部和全局时间戳编码。

3.1.2 注意力模块

自注意力机制是Transformer模型的核心部分，它依靠参数少、并行计算且有效建模长距离依赖关系的优势，能够有效完成LSTF任务。但其$O(L^2)$的复杂度和高内存需求成为长时间序列预测的瓶颈。近期更多研究解决这一挑战，更高效的Transformer模型被提出解决二次复杂度问题，可分为三类：（1）将稀疏性引入注意力机制，使用启发式算法解决二次复杂度问题，如LogTrans[77]使用对数稀疏注意，达到$O(L(\log L)^2)$复杂度。（2）使用top-k截断加速计算，如Informer[79]基于长尾分布进行top-k截断，选取活跃Q进行计算，达到$O(L\log L)$复杂度；Autoformer[80]引入自相关注意力模块，通过快速傅里叶变换和top-k选择，实现$O(L\log L)$复杂度。（3）采用注意力矩阵的低秩近似，如FEDformer[81]提出一种频率低秩近似和混合分解的注意力模块，通过频率增强结构解耦序列长度和注意力矩阵，实现$O(L)$线性复杂度。

3.1.3 模型结构

为使Transformer中各个模块更好适应LSTF任务，一些研究在模型架构层面对Transformer模型进行了改造创新。其中Zhou等人[79]在相邻自注意力模块加入卷积池化的蒸馏操作，对特征进行下采样并构建多个副本。Liu等人[82]引入了金字塔结构注意力，利用树结构传递注意力，从不同尺度捕获时序间依赖关系。Zhang等人[83]采用多层金字塔编码器-解码器结构，实现不同尺度建模。

3.1.4 通用框架

最近有研究提出通用框架，可用于多种时序预测Transformer模型，有效提高原模型预测性能。Liu等人[84]提出去平稳框架，解决处理原始时序数据时造成的过度平稳化问题；同时Liu等人[85]近期提出了一种倒置输入方式，重新分配了注意力模块与前馈神经网络的作用，可有效提升最先进模型性能。Shabani等人[86]多尺度迭代框架，通过多尺度迭代捕获不同尺度间的依赖关系和特征，引入跨尺度归一化解决时序数据分布偏移问题。Zhang等人[87]引入图结构学习不同序列间关系，利用了全局可交互标记捕获全局信息，在不影响复杂度情况下有效提高Transformer模型性能。

3.2 LogSparse Transformer

2019年，Li等人[78]提出了LogSparse Transformer。在TSF（time series forecasting）任务中早晚高峰、假期和极端天气等事件，观测点是真异常还是伪异常高度依赖于周围环境变化。而Transformer中逐个点积的自注意力机制对局部上下文不敏感，无法有效利用局部信息，因此设计了因果卷积的自注意力。如图4所示，使用卷积核为k与步长为1的因果卷积将输入转换为$\boldsymbol{Q}$和$\boldsymbol{K}$。通过因果卷积生成的$\boldsymbol{Q}$和$\boldsymbol{K}$能更好了解局部上下文，可通过局部信息来计算其相似性，有助于提高预测准确性。当k=1时，卷积自注意力将退化为规范自注意力，可看作一种泛化。

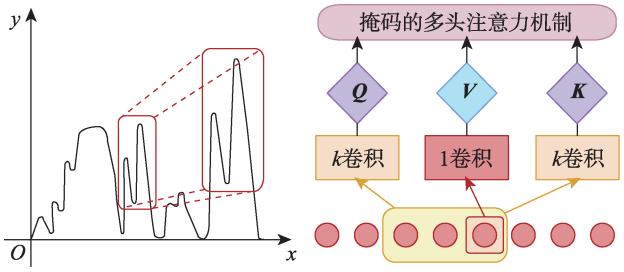

图4 卷积自注意力结构示意图

Fig.4 Schematic diagram of convolution self-attention structure

由于传统自注意力机制的空间复杂度为$O(L^2)$，将注意力扩展到极长序列在计算上存在困难。针对存储瓶颈问题，作者提出了LogSparse机制。实验证明引入某种程度的稀疏性，不会显著影响性能，反而使模型具

中国知网 https://www.cnki.net

备了处理细粒度和长期依赖的能力。实验表明Log-Sparse机制通过堆叠多个自注意力层将空间复杂度降为$O(L(\log L)^2)$。

3.3 Informer

2021年，Zhou等人[79]提出了用于超长时间序列预测的高效Transformer模型Informer。传统Transformer模型主要存在三个问题：自注意力机制的二次计算复杂度、内存占用瓶颈和动态解码预测输出效率低。作者针对这些问题，提出了稀疏自注意力机制、自注意力蒸馏操作和生成式解码器。Informer在传统Transformer基础上进行了改进（如图5所示）。

研究表明传统自注意力点积运算呈现长尾分布稀疏性，只有少量点积运算对自注意力得分做出了贡献，其余点积可以忽略。作者从概率角度出发，使用KL散度计算$\boldsymbol{Q}$注意力与均匀分布的概率分布相对熵，相对熵越大，说明$\boldsymbol{Q}$对自注意力得分贡献越大。选取top-u个$\boldsymbol{Q}$，将复杂度降为$O(L\ln L)$，解决了传统自注意力机制的二次复杂度问题。

作者在相邻的自注意力模块加入了卷积池化操作，对特征进行下采样。同时为增强鲁棒性，还构建了多个主序列长度减半的副本，经过蒸馏操作后，拼接成编码器的输入。通过下采样特征更加明显且模式不变，解决了内存占用瓶颈的问题。

传统Transformer解码器是动态解码的过程，需要逐步迭代输出，输出效率低的同时还会造成误差累积。作者把目标序列之前的已知序列作为开始序列，将目标序列填0掩盖，直接生成多步预测结果，解决了动态解码效率低的问题。

在长序列预测任务中，不仅需要局部时间戳及位置编码，还需要全局信息来捕获长序列，如星期、月、年、假期和事件等。因此作者对时序输入进行了处理，在局部时间戳的基础上加入了全局时间戳，增强了输入表示的全局位置信息和局部时序信息。作者针对效率和内存占用问题，在计算复杂度和解码形式上进行了改进，使Informer模型在长时预测任务取得了优秀的性能。

3.4 Autoformer

2021年，Wu等人[80]提出了用于长期预测的自相关分解Transformer模型Autoformer。虽然稀疏注意力机制解决了二次复杂度问题，但是限制了信息利用率。而且在长时预测中由于复杂的时间模式，自注意力机制难以捕获可靠依赖。因此设计了Autoformer深度分解架构，首次将时间序列分解融入到Transformer架构中，其中包括序列分解单元、自相关机制和对应的编码器-解码器。

通过序列分解单元将时间序列分解为如趋势周期项和季节项等潜在时间模式。在预测过程中，逐步从隐变量中分离趋势周期项和季节项，实现渐进式分解，且模型交替进行预测结果优化和序列分解，实现两者相互促进。具体通过调整移动平均线平滑周期波动，突出长期趋势，计算方法如式(9)所示：

$$\begin{cases} \boldsymbol{X}_{\mathrm{t}} = \mathrm{AvgPool}(\mathrm{Padding}(\boldsymbol{X})) \\ \boldsymbol{X}_{\mathrm{s}} = \boldsymbol{X} - \boldsymbol{X}_{\mathrm{t}} \end{cases} \tag{9}$$

其中，$\boldsymbol{X}$为待分解变量，$\boldsymbol{X}_{\mathrm{t}}$和$\boldsymbol{X}_{\mathrm{s}}$分别为趋势周期项和季节项。

通过实验观察，不同周期相似相位之间通常表现出相似子过程，利用这种序列固有周期性设计自相关机制，通过计算序列之间自相关来捕获基于周期依赖关系，并通过时间延迟聚合模块对齐相似周期子序列。

在编码器中逐步消除趋势周期项，得到季节项，通过自相关机制，聚合不同周期相似子过程，实现信息聚

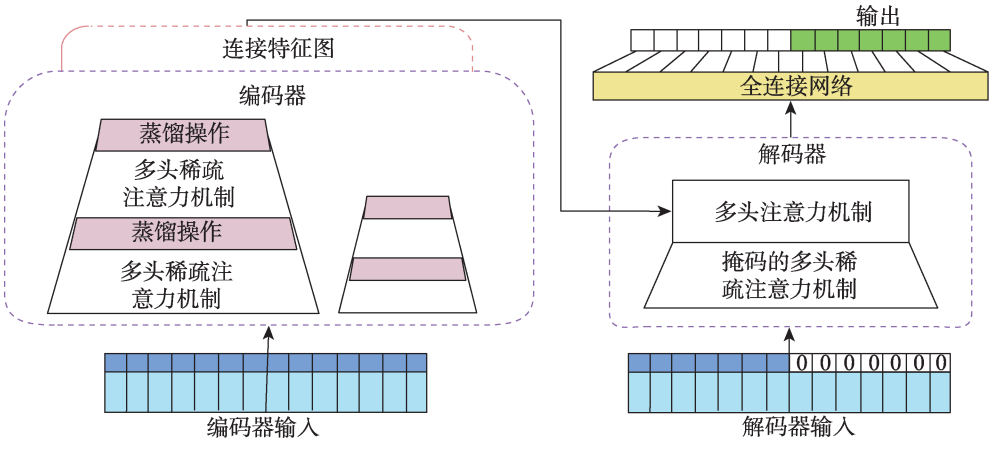

图5 Informer结构示意图

Fig.5 Schematic diagram of Informer structure

中国知网 https://www.cnki.net

合。在解码器中对趋势周期项与季节项分别建模。对于趋势项，使用累积方式逐步从预测的隐变量中提取趋势信息。

作者在Transformer基础上添加了分解单元提取序列中更为复杂时间模式，并基于随机过程理论提出了自相关机制，代替点向连接自注意力机制，不仅保证了$O(L\log L)$的复杂度，且能更好捕捉趋势性，打破信息利用瓶颈。在长期预测问题中，Autoformer在能源、交通、经济、气象、疾病五大时序领域大幅超越之前最优模型，实现38%相对效果提升。

3.5 Triformer

2022年，Cirstea等人[88]提出了一种三角形层次结构的特定变量参数Transformer模型Triformer。引入线性复杂度补丁注意力并采用一种轻量级方法来生成特定变量参数，解决高复杂度和准确性问题。

为应对高复杂性，Triformer沿时间维度将输入序列分解为补丁，在每个补丁中引入一个可学习伪时间戳，达到线性复杂度。同时为补偿因补丁注意力而减小的感受野，引入一个循环连接每个补丁的输出。Triformer具有三角形结构，因此将补丁伪时间戳馈送到下一层时，会以指数方式缩小。所有层总和输出预测，不仅捕获不同时间尺度特征，且提供多个梯度反馈路径。通过为每个变量引入不同投影矩阵进行矩阵分解，可实现特定变量建模。除了减少参数，分解还能提高精度，促进变量间隐式关系。

Triformer三角形结构采用补丁注意力，确保了线性复杂性，提出一种轻量级方法来生成特定变量投影矩阵，用于捕获不同时间模式。在四个数据集上实验表明，该方法优于其他长序列多元时间序列预测方法。

3.6 FEDformer

2022年，Zhou等人[81]提出了用于长期预测的频率增强分解Transformer模型FEDformer。在TSF任务中，序列的分布可能随时间的推进不断变化，如模型输入和真实值分布差异较大，导致模型的预测值不准确。为了应对分布偏移和噪声影响，作者首次将时频转换融入到了Transformer架构中。利用傅里叶变换和小波变换将序列从时域转换到频域进行表征学习来提取特征，并使用一种低秩近似注意力机制来控制分布偏移。在编码-解码器的内部额外添加了频域增强模块、频域注意力模块、混合分解模块（如图6所示）。

傅里叶变换及其逆变换可实现序列在时域和频域之间相互转换，利用频域信息稀疏性和还原性，设计了频域增强模块和频域注意力模块。首先通过投影在频域中进行随机采样，减少信息冗余，降本增效。经过学习阶段补全频域部分，将未被采样频率点补零，使得序列能够还原回原始长度。最后投影回时域，重构后序列与之前的输入维度完全一致。

频域注意力模块达到了线性复杂度$O(L)$。通过频域随机采样，利用少量点就能够还原大部分信息，采样后得到小矩阵是原矩阵的低秩近似。理论证明频域随机采样造成的信息损失不会超过一个上界。

由于傅里叶变换在面对非平稳序列时具有局限性，设计了小波变换增强模块，针对多个局部时序数据进行投影并分解重构，从而有效捕获局部信息。

将趋势季节分解和频域转换同Transformer架构相结合，能更好捕获全局特征，并通过随机采样，实现了线性复杂度和内存占用。FEDformer模型在多变量和单变量预测任务中分别比最佳性能提升了14.8%和22.6%。

3.7 Pyraformer

2022年，Liu等人[82]提出了一种低复杂度金字塔注意力的Transformer模型Pyraformer（如图7所示）。为应对长距离依赖和复杂度问题，作者设计了一种金字塔注意力，利用树结构传递注意力信息，以捕捉远程依赖并降低复杂度。

嵌入观测数据和协变量后，利用粗尺度构造模块构建一个多尺度C叉树，初始化金字塔图粗尺度节点（月、

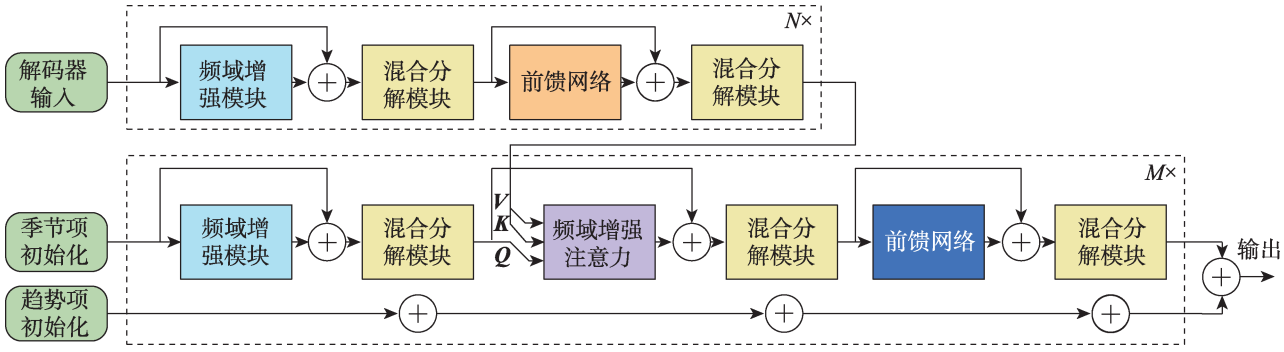

图6 FEDformer结构示意图

Fig.6 Schematic diagram of FEDformer structure

中国知网 https://www.cnki.net

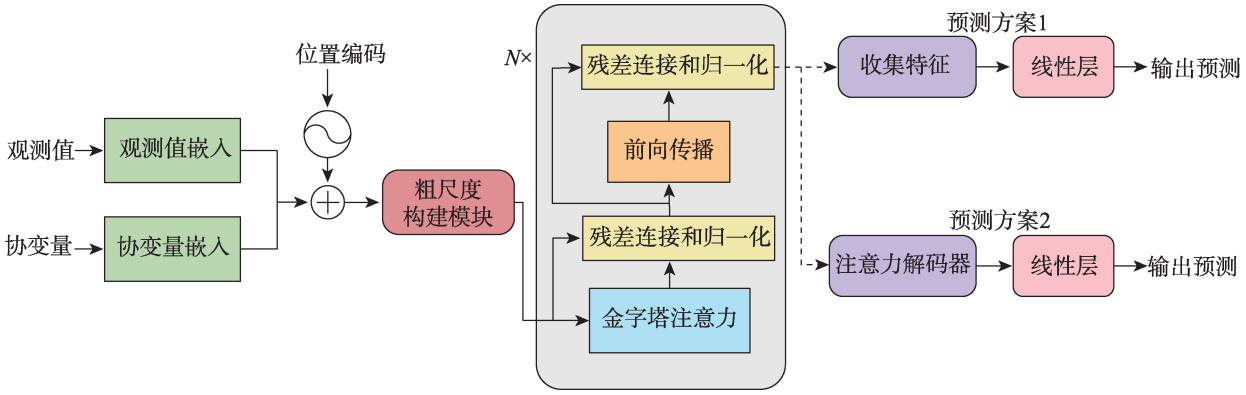

图7 Pyraformer结构示意图

Fig.7 Schematic diagram of Pyraformer structure

周、日），包含相应细尺度节点信息。然后通过金字塔注意力模块传递消息，尺度间连接建立不同分辨率特征，尺度内连接通过相邻节点捕捉远程依赖。最后根据下游任务采样不同网络结构输出最终预测。实验证明Pyraformer在单步和长时多步预测任务中均取得了最佳性能且计算时间和存储成本较低。

3.8 Non-stationary Transformers

2022年，Liu等人[84]提出去平稳Transformer通用框架Non-stationary Transformers。利用去平稳注意力将序列丢失的非平稳化特征重新表征，且能广泛用于其他Transformer变体提升其性能。

以往研究通常采用平稳化操作减弱原始时序数据非平稳性，但过度平稳化会忽略突发事件包含的重要信息，阻碍了模型预测能力。因此作者设计了序列平稳化模块，增强输入数据的平稳性，通过平稳注意力模块重新整合非平稳信息，缓解过平稳问题。

序列平稳模块的两个阶段分别封装在模型的前后层。首先归一化消除不同变量间尺度差异，为模型提供更稳定数据，然后逆归一化利用原数据均值和方差进行反向变换，恢复丢失分布信息。同时内部的去平稳注意力模块利用归一化时存储的统计量近似捕获原始非平稳数据特征和时间依赖。实验证明Non-stationary Transformers是一个有效且轻量的框架，可应用在Transformer及其变体上，保留了原有的复杂度的同时能有效提升性能，特别是非平稳数据。

3.9 TDformer

2022年，Zhang等人[89]通过分析时域注意力、傅里叶变换频域注意力和小波变换频域注意力三种不同注意力机制的特点和使用场景，根据结论提出了TDFormer。

首先从数学角度证明了在线性条件下，三种注意力机制是等效的。由于注意力计算中Softmax函数的存在，使得三种注意力机制在强季节性、强趋势性、高噪声序列中有着不同效果。对于强季节性序列，频域注意力机制效果更好，尤其是多重季节性序列，小波变换注意力更胜一筹。对于强局势性序列，注意力模型表现出较差泛化性，不如线性模型，因为线性模型外推能力更强。对于高噪声序列，频域注意力机制会削弱噪声影响，具有更强鲁棒性。

显然季节项和趋势项适合采用分别建模，因此在TDFormer中，使用傅里叶变换在频域对季节项建模，使用标准化和MLP多层感知机对趋势项进行建模。实验证明TDFormer依靠分别建模方式，在准基上取得了先进性能。

3.10 PatchTST

2023年，Nie等人[90]提出了PatchTST。先前研究工作主要集中在简化自注意力机制，然而逐点注意力机制只能关注当前信息，不能有效考虑前后时间信息联系。因此作者借鉴了Vision Transformer中分段操作，设计了包含分割补丁技术和独立通道技术的PatchTST模型（如图8所示），包括有监督和自监督两种结构。其中自

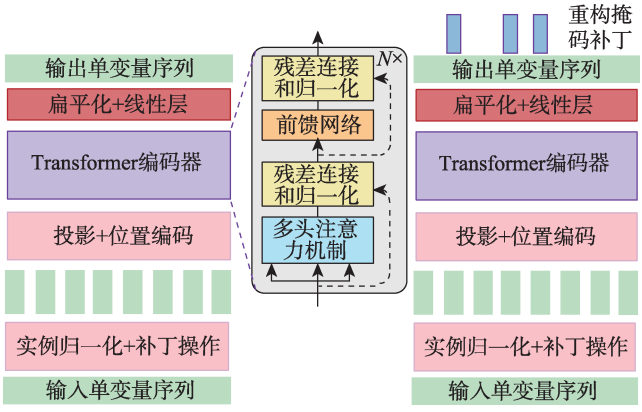

图8 PatchTST结构示意图

Fig.8 Schematic diagram of PatchTST structure

中国知网 https://www.cnki.net

监督结构将补丁进行掩码操作，避免模型从前后元素推测出被掩盖信息。

补丁即多次分割的时间序列，分割补丁不仅能降低复杂度，减少参数数量防止过拟合，更能保留时间序列局部性，为后续自监督学习提供便利。

将多维序列中每个维度单独进行处理，每个单变量序列分别输入主干网络，将输出结果拼接得到预测结果。实验证明不同通道序列可以学习不同注意力模式，能提高收敛速度，因此优于混合通道。此外独立通道技术可通过使用图神经网络等方法学习跨通道关系，并对噪声具有更强鲁棒性。

PatchTST模型引入分割补丁和独立通道，有效提取时间序列数据中局部信息，使模型训练速度更快且有更长输入窗口，并在自监督学习和迁移学习中有良好能力。

3.11 Conformer

2023年，Li等人[91]提出了Conformer模型以解决低复杂度带来的信息利用瓶颈问题。作者在Transformer基础上引入滑动窗口注意力和平稳瞬时循环网络模块，并利用归一化流操作捕获网络中潜在状态，直接生成预测目标。

具体来说，Conformer首先通过快速傅里叶变换和多尺度动态提取对序列进行预处理并嵌入，探索时间序列多元相关性和不同时间模式。然后利用滑动窗口注意力模块捕获局部模式，每个位置只和附近窗口邻居节点做注意力计算，避免完整注意力造成冗余，将复杂度降低至$O(L)$。

由于稀疏连接牺牲信息利用率，利用循环神经网络捕获序列动态的能力，提出平稳瞬时循环网络模块提取序列中趋势模式和季节模式。此外为缓解时间序列数据随机不确定性带来波动效应，设计了一个归一化流块潜在状态，并直接生成目标序列，进一步提高了信息利用率且具有更好抗噪性。

3.12 Scaleformer

2023年，Shabani等人[86]提出了一种多尺度迭代的通用框架Scaleformer，用于基于Transformer的时间序列预测模型。结构如图9所示，通过多尺度迭代捕捉不同尺度间的依赖关系和特征，并引入一种跨尺度归一化方法解决分布偏移问题，同时采用自适应损失解决迭代造成的误差累积。

Scaleformer将时间序列从低频到高频进行采用，依次迭代到更高频的解码器中，低频序列更平滑，而高频序列保留了更多细节。由于解码器和编码器的数据来源不同，前者是原始序列的采样，后者是上一步的预测输出，数据分布之间存在偏差，而且输入更高频时不同尺度之间也存在分布偏移。因此进行跨尺度归一化操作缓解这种情况。实验证明该框架应用在最佳性能模型上，能够以最小的额外计算开销，实现显著性能提升，可将均方误差降低5.5%至38.5%。

3.13 Crossformer

2023年，Zhang等人[92]提出了跨维度依赖的多变量Transformer模型Crossformer。传统基于Transformer模型主要关注于跨时间依赖，但对于多变量时序预测任务，跨维度依赖尤为重要。

因此Crossformer对多变量序列输入进行维度分段嵌入，对每个维度进行单独向量化表征，保留时间和维

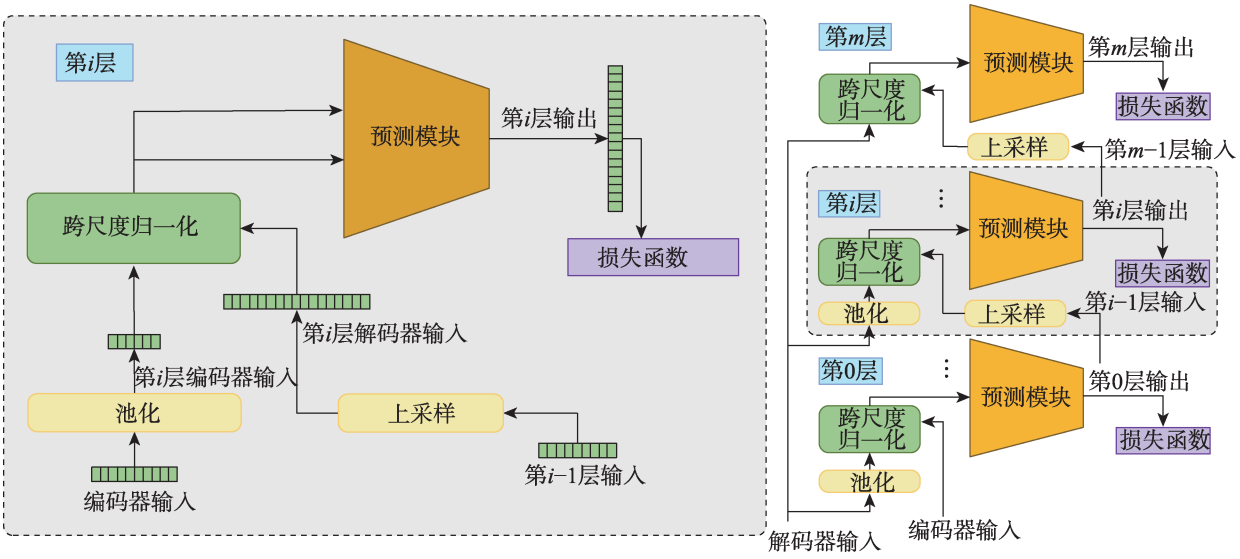

图9 Scaleformer结构示意图

Fig.9 Schematic diagram of Scaleformer structure

中国知网 https://www.cnki.net

度信息。提出了两阶段注意力，先经过时间维度注意力机制，捕捉每个变量时间依赖，再进行变量维度注意力机制，对齐不同变量时间步，提取多个变量之间关系。构建分层编码器-解码器结构，对不同阶段结果进行解码，随着层级增加，模型从不同粗细粒度提取信息，利用不同层级信息进行预测得到最终结果。实验证明Crossformer在6个真实数据集上达到了先进性能。

3.14 MTPNet

2023年，Zhang等人[83]提出了一个多尺度金字塔Transformer模型MTPNet（如图10所示）。利用多层不同尺度Transformer结构解决了固定尺度或受约束尺度的时间依赖性建模问题。

MTPNet对趋势项和季节项进行了分别建模，这在先前研究被证实是有效的时序分解方式，能学习复杂季节和趋势成分。

采用分割补丁方式处理多元序列，同时舍弃传统沿时间维度嵌入和沿变量维度嵌入，采用维度不变嵌入方式。通过一个3×1卷积将数据嵌入到特征映射中提取维度信息，进行沿时间维度分段处理，保持变量和时间维度不变。

为实现不同尺度建模，MTPNet采用了多层编码器-解码器结构。每一层对应一种尺度，第k层信息通过拼接融合$k-1$层编码结果。最后将k个潜在表征连接起来，通过卷积投影出预测值。实验表明从多尺度潜在表征推断预测过程能够有效利用大范围无约束尺度时间依赖性，提高预测精度。

3.15 SageFormer

2024年，Zhang等人[86]提出了序列感知的图增强Transformer框架SageFormer。为解决序列间依赖关系建模问题，SageFormer将GNN与Transformer结合，通过图结构学习，使用图邻接矩阵表示不同序列之间关系，能有效捕获各种时间模式并利用序列之间依赖关系。

为有效表示序列中不同时间模式，SageFormer在分补丁输入后，在每个变量序列前加入全局可交互标记以捕获全局信息，利用序列随机初始化嵌入学习变量间的图结构，通过聚合实现序列间信息交互。为减少跨序列冗余信息影响，使用了稀疏连接的图结构。收集所有序列中全局标记，通过GNN组件进行图增强处理后返回原始序列，并输出时间编码，其将作为下层全局标记，反复迭代后捕捉到各序列之间依赖性。实验证明SageFormer在真实数据集和合成数据集上达到最先进性能，同时作为通用框架，能在不影响复杂度情况下，有效提高Transformer类模型性能。

3.16 iTransformer

2024年，Liu等人[85]提出了一种转置的Transformer模型iTransformer。针对Transformer模型比线性模型预测效果差的问题，作者发现在多变量预测中单一时间点包含不同维度信息，每个时间步统一嵌入会导致模型学习到无意义注意力图，削弱不同变量相关性，并面临时间戳不对齐和感受野小的问题。

为此，iTransformer转置了原本时间维度输入，将同一变量维度的时间序列作为输入，同时重新分配了注意力模块与前馈网络的作用。通过多变量注意力机制建模不同变量之间相关性，增强多变量时序预测可解释性。对每个变量单独进行归一化，保证变量独立性，解决采样不对齐和时滞性问题。利用前馈网络建模每个变量内部时序相关性，提取时间维度表征。实验证明iTransformer达到了最先进性能，将转置方法与Transformer类模型结合，效果有效提升且接受更长输入，具

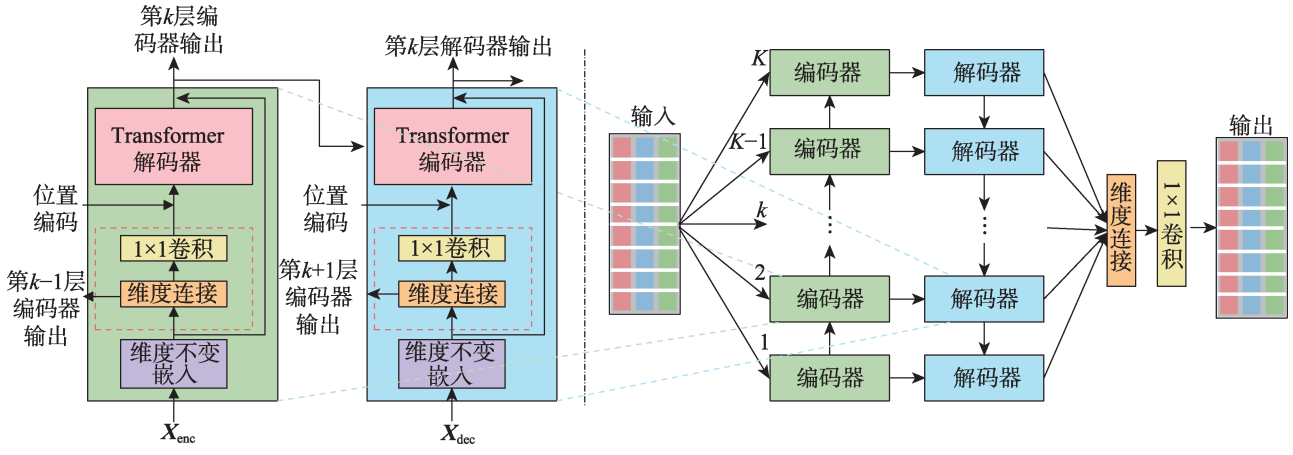

图10 MTPNet结构示意图

Fig.10 Schematic diagram of MTPNet structure

中国知网 https://www.cnki.net

有泛化能力和通用性。

3.17 Pathformer

2024年，Chen等人[93]提出了具有自适应路径的多尺度Transformer模型Pathformer（如图11所示），解决了有限或固定尺度难以捕捉不同尺度特征问题。整个网络结构由实例归一化模块、自适应多尺度模块和预测器组成。

实例归一化用于解决训练数据和测试数据之间分布偏移。预测器是一种全连接的神经网络。核心为多自适应尺度模块，由多尺度Transformer模块和自适应路径组成。

多尺度Transformer模块分为多尺度补丁分割和双重注意力。双重注意力通过补丁间注意力捕获全局特征，补丁内注意力捕获局部细节。自适应路径包含多尺度路由器和多尺度聚合器。多尺度路由器通过内部时间分解模块提取周期和趋势模式，根据输入数据选择最优尺寸补丁，控制多尺度建模。多尺度聚合器通过转换函数将不同尺度序列维度对齐，加权聚合输出。

Pathformer通过引入多尺度补丁分割和双重注意力，集成多尺度时间分辨率和距离，实现多尺度特征综合建模。此外自适应路径根据不同时序动态选择并聚合多尺度特征。这些创新使Pathformer取得了最先进性能，并在多个预测任务中有较强泛化能力。

3.18 Transformer模型对比

数据集：经过2.2节分析，Exchange和ILI数据集缺乏较强的周期性或季节性且数据量较少，不利于Transformer模型的长距离建模。因此，本文选取了ETTm2、Electricity、Traffic和Weather数据集进行实验。

实验细节：所有模型数据遵循相同的输入长度为96，预测长度为{96，192，336，720}，选择Adam优化器，选取MSE和MAE作为评价指标，使用PyTorch进行算法实现。

对上述Transformer类模型进行性能对比，如表2所示。

对表2中所列的各种模型实验数据进行了深入分析和总结，结论如下：

第一，各模型在输入长度固定时，随着预测长度增加，预测效果逐渐下降，这是直接多步预测策略导致的。在长序列预测任务中，直接多步预测虽然会提高预测速度，减少误差传播，但一次性生成全部预测结果在很大程度上减弱了当前时间点与上一时间点的信息相关性，使得预测效果下降。

第二，各模型在Traffic数据集上的预测效果相较于其他数据集较差。这是由于Traffic数据属于交通流量预测，需要考虑不同道路段之间的空间相关性。该数据集包含高达862维的变量，这使得模型不仅需要在时间维度上捕获依赖关系，还需要捕获空间分布的动态性。其中SageFormer[87]采用GNN结构一定程度上捕捉了时空关系，因此在Traffic数据集中取得了较好效果。

第三，通过实验数据还可发现，随着注意力机制不断改进创新，序列分解逐渐完善，模型架构不断优化，模型预测性能随之提高。其中，Autoformer[80]、FEDformer[81]和TDformer[89]探索了序列分解技术与Transformer的建模方法，Pyraformer[82]、MTPNet[83]和Path-

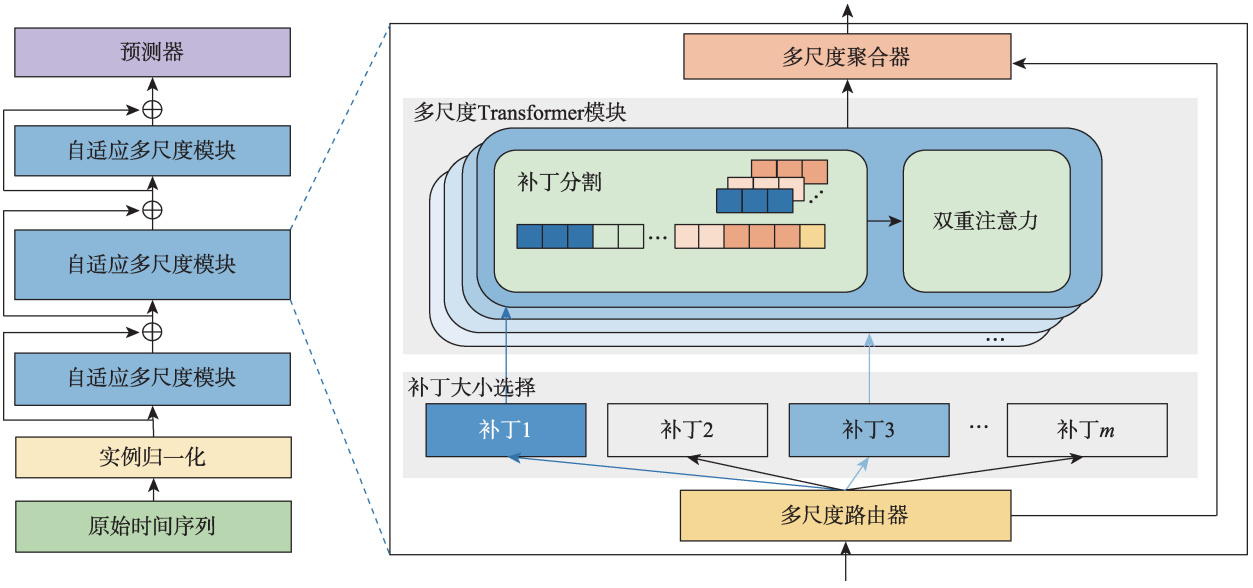

图11 Pathformer结构示意图

Fig.11 Schematic diagram of Pathformer structure

中国知网 https://www.cnki.net

表2 Transformer类模型多变量预测性能对比

Table 2 Comparison of multivariate prediction performance of Transformer models

模型	评价指标	ETTm2				Electricity				Traffic				Weather			
		96	192	336	720	96	192	336	720	96	192	336	720	96	192	336	720
LogSparse Transformer[78]	MSE	0.768	0.989	1.334	3.048	0.258	0.266	0.280	0.283	0.684	0.685	0.734	0.717	0.458	0.658	0.797	0.869
	MAE	0.642	0.757	0.872	1.328	0.357	0.368	0.380	0.376	0.384	0.390	0.408	0.396	0.490	0.589	0.652	0.675
Informer[79]	MSE	0.365	0.533	1.363	3.379	0.274	0.296	0.300	0.373	0.719	0.696	0.777	0.864	0.300	0.598	0.578	1.509
	MAE	0.453	0.563	0.887	1.338	0.368	0.386	0.394	0.439	0.391	0.379	0.420	0.472	0.384	0.544	0.523	0.741
Autoformer[80]	MSE	0.255	0.281	0.339	0.433	0.201	0.222	0.231	0.254	0.613	0.616	0.622	0.660	0.266	0.307	0.359	0.419
	MAE	0.339	0.340	0.372	0.432	0.317	0.334	0.338	0.361	0.388	0.382	0.337	0.408	0.336	0.367	0.395	0.428
FEDformer[81]	MSE	0.203	0.269	0.325	0.421	0.193	0.201	0.214	0.246	0.587	0.604	0.621	0.626	0.217	0.276	0.339	0.403
	MAE	0.287	0.328	0.366	0.415	0.308	0.315	0.329	0.355	0.366	0.373	0.383	0.382	0.296	0.336	0.380	0.428
Pyraformer[82]	MSE	0.435	0.730	1.201	3.625	0.386	0.386	0.378	0.376	0.867	0.869	0.881	0.896	0.622	0.739	1.004	1.420
	MAE	0.507	0.673	0.845	1.451	0.449	0.443	0.443	0.445	0.468	0.467	0.469	0.473	0.556	0.624	0.753	0.934
Non-stationary Transformer[84]	MSE	0.192	0.280	0.334	0.417	0.169	0.182	0.200	0.222	0.612	0.613	0.618	0.653	0.173	0.245	0.321	0.414
	MAE	0.274	0.339	0.361	0.413	0.273	0.286	0.304	0.321	0.338	0.340	0.328	0.355	0.223	0.285	0.338	0.410
TDformer[89]	MSE	0.174	0.243	0.308	0.400	0.160	0.172	0.186	0.215	0.545	0.571	0.589	0.606	0.177	0.224	0.278	0.368
	MAE	0.256	0.302	0.344	0.400	0.263	0.275	0.290	0.313	0.320	0.329	0.331	0.337	0.215	0.257	0.290	0.351
PatchTST/64[90]	MSE	0.166	**0.223**	0.274	0.362	0.129	0.147	**0.163**	**0.197**	**0.360**	**0.379**	**0.392**	**0.432**	0.149	0.194	0.245	0.314
	MAE	0.256	0.296	0.329	0.385	0.222	0.240	0.259	**0.290**	0.249	0.256	0.264	0.286	0.198	0.241	0.282	0.334
Crossformer[92]	MSE	0.444	0.833	0.766	0.959	0.141	0.166	0.323	0.404	0.538	0.515	0.530	0.573	0.158	0.194	0.495	0.526
	MAE	0.463	0.657	0.620	0.752	0.240	0.265	0.369	0.423	0.300	0.288	0.300	0.313	0.231	0.262	0.515	0.542
MTPNet[83]	MSE	**0.164**	0.223	**0.273**	**0.356**	**0.128**	**0.146**	0.164	0.203	0.401	0.431	0.453	0.491	**0.146**	**0.188**	**0.238**	**0.310**
	MAE	**0.248**	**0.291**	**0.325**	**0.380**	**0.219**	**0.237**	**0.256**	0.293	**0.234**	**0.247**	**0.259**	**0.284**	**0.189**	**0.230**	**0.271**	**0.322**
SageFormer[87]	MSE	0.173	0.239	0.299	0.395	0.147	0.161	0.180	0.213	0.408	0.421	0.438	0.477	0.162	0.211	0.271	0.345
	MAE	0.255	0.299	0.338	0.395	0.246	0.259	0.279	0.309	0.271	0.279	0.283	0.308	0.206	0.250	0.294	0.343
iTransformer[85]	MSE	0.180	0.250	0.311	0.412	0.148	0.162	0.178	0.225	0.395	0.417	0.433	0.467	0.174	0.221	0.278	0.358
	MAE	0.264	0.309	0.348	0.407	0.240	0.253	0.269	0.317	0.268	0.276	0.283	0.302	0.214	0.254	0.296	0.347
Pathformer[93]	MSE	0.170	0.238	0.293	0.390	0.145	0.167	0.186	0.231	0.479	0.484	0.503	0.537	0.156	0.206	0.254	0.340
	MAE	0.248	0.295	0.331	0.389	0.236	0.256	0.275	0.309	0.283	0.292	0.299	0.322	0.192	0.240	0.282	0.336

注：粗体结果表示最佳性能，下划线结果表示第二优性能。实验结果引自iTransformer、Pathformer、Sageformer、MTPNet、Crossformer、PatchTST和TDformer实验部分。

former[93]在多尺度特征建模方面具有优势，PatchTST[90]、Crossformer[92]、MTPNet[83]、SageFormer[87]和Pathformer[93]得益于补丁分段方法和通道独立技术，达到了最先进性能，而iTransFormer[85]通过转置时间维度输入，重新分配了注意力模块和前馈网络的作用，在不修改任何模块的情况下同样达到最先进性能。

表2中的数据分析可视化结果如图12所示。

3.19 分析与讨论

对上述Transformer类模型进行总体分析，如表3所示。起初Transformer中逐个点积的自注意力机制对局部信息不敏感且有二次复杂度。LogSparse Transformer[78]做出了改进，通过因果卷积提取局部特征，不仅性能提升，且一定程度解决了二次复杂度问题。但复杂度和内存瓶颈问题仍是一项挑战。Informer[79]提出稀疏注意力和自注意力蒸馏操作，利用长尾分布的稀疏性，采样top-k截断进一步解决了复杂度问题，并引入生成式解码器和时间戳编码，提高效率同时取得了优秀性能。虽然稀疏注意力解决了二次复杂度问题，但限制了信息利用率。Autoformer[80]利用时间序列分解提取复杂的时间模式并提出自相关机制，保证低复杂度的同时更好捕获趋势性和季节性等时间模式，打破信息利用瓶颈。FEDformer[81]在时间序列分解的基础上，利用傅里叶变换和小波变换将序列转换到频域进行表征学习以提出特征，并使用低秩近似注意力控制分布偏移且达到了线性复杂度。Pyraformer[82]在模型结构进行创新，设计了金字塔结构注意力并通过多尺度C叉树传递注意力信息，有效捕获长距离依赖和复杂度问题。Non-stationary Transformer[84]针对数据过平稳化问题，提出一

中国知网 https://www.cnki.net

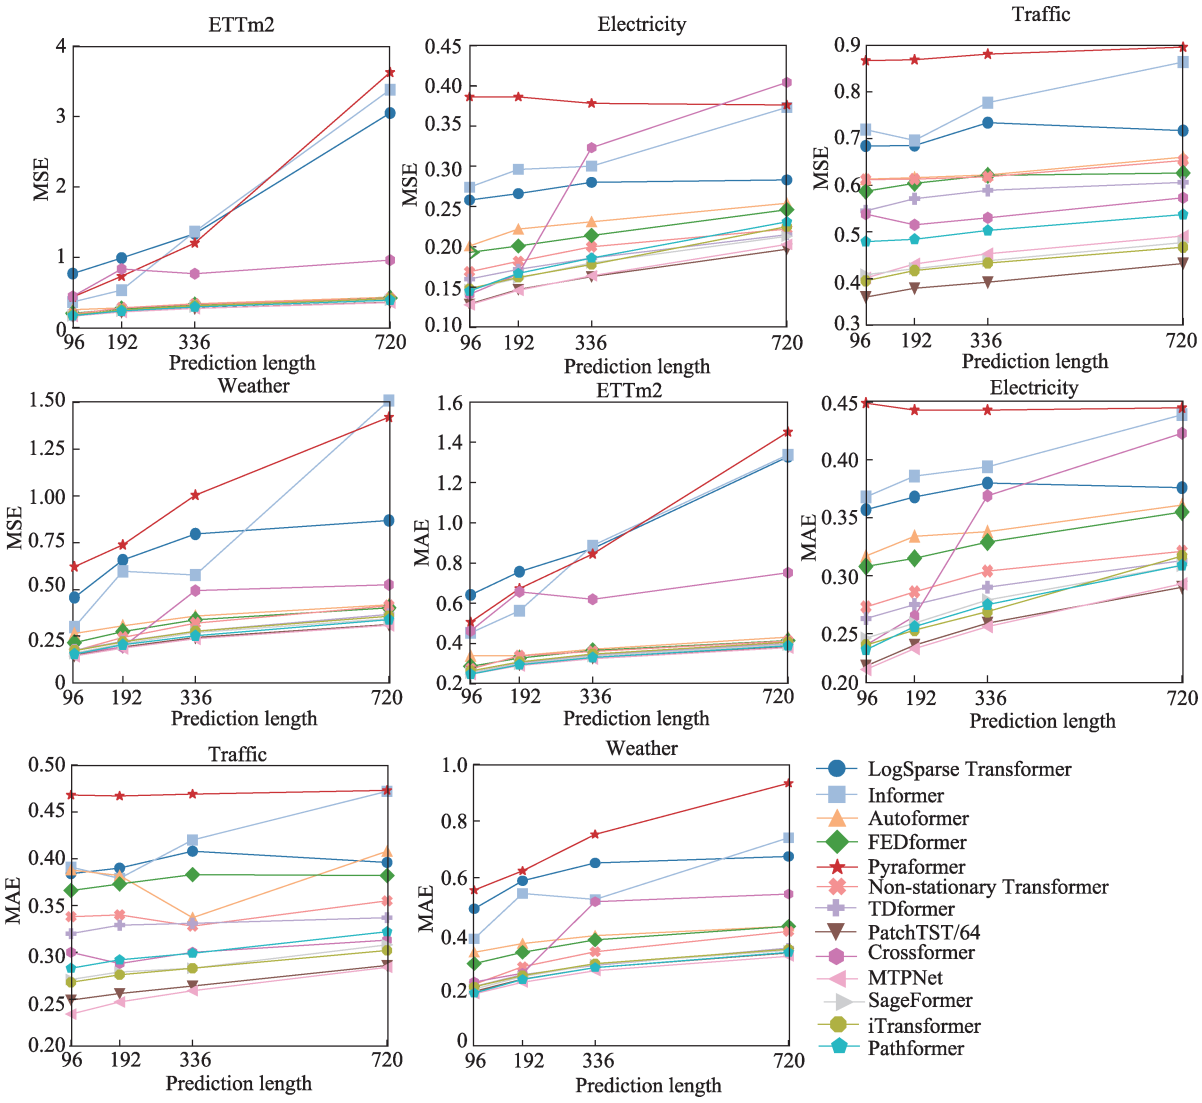

图12 在{96,192,336,720}预测长度下MSE和MAE预测结果

Fig.12 MSE and MAE prediction results at {96, 192, 336, 720} prediction length

个通用框架，利用平稳化模块恢复丢失的局部信息。该框架可以应用在先前的Transformer模型上提升其性能且保留原复杂度。先前Autoformer和FEDformer在时间序列分解和时频域转换方向做出了创新。TDformer[89]对比了时域注意力、傅里叶变换频域注意力和小波变换频域注意力不同的适用场景，提出季节项和趋势项适合分别建模。先前工作主要集中在简化注意力机制降低复杂度，忽略了前后时间信息的联系和性能。PatchTST[90]借鉴了Vision Transformer中的分补丁操作，保持了时间序列的局部性，提出的独立通道技术也广泛应用在以后研究中。以往的研究主要关注于跨时间依赖，Crossformer[92]对多变量序列进行维度分段嵌入，对每个维度单独向量化表征，保留时间和维度信息。MTPNet[83]结合了先前工作，对时间序列分解进行分别建模，采用分割补丁处理多元序列并设计了维度不变的嵌入方式，利用多层金字塔编码器解码器结构实现多尺度建模。长期多元时序预测面临着同时捕获序列内和序列间依赖关系的挑战，Sageformer[87]利用图神经网络(GNN)捕获多元时间序列中的依赖关系，将不同变量的时间序列视为图节点并通过图结构学习建立关系，设计了全局令牌捕获序列内信息并通过交互增强序列间信息。先前工作通常将同一时间戳的多个变量融合为一个嵌入向量，无法有效学习变量为中心的表示。iTransformer[85]在模型结构方面进行了创新的反转，将注意力机制和前馈网络的职责重新分配，对每个变量序列独立嵌入，利用注意力机制捕捉多变量之间的相关性，同时使用前馈网络对每个变量的时间序列进行非线性表示学习。Pathformer[93]在PatchTST的基础上改进

中国知网 https://www.cnki.net

表3 Transformer 类算法总体分析

Table 3 Overall analysis of Transformer models

模型	改进方式	优势	局限性
LogSparse Transformer[78]	针对点积自注意力局部上下文不敏感问题，提出卷积自注意；针对二次增长空间复杂度问题，模型仅$O(L(\log L)^2)$内存开销r	通过卷积核为k和步长为1因果卷积生成Q和K，更好捕获局部信息，解决了内存瓶颈问题	在实际应用中，减少的内存消耗是有限的
Informer[79]	针对二次时间复杂度问题，提出稀疏自注意力；针对堆叠网络内存占用瓶颈问题，提出自注意力蒸馏操作；针对动态解码效率低和误差累积问题，提出生成式解码器	在时间复杂度和内存使用上达到$O(L \log L)$，能更有效处理长序列，提高预测速度	牺牲信息利用率，导致信息利用瓶颈，使得预测误差提高
Autoformer[80]	针对信息利用瓶颈问题和复杂时间模式，提出序列分解单元和自相关机制	渐进式分解优化了预测结果，序列级别的自相关机制，在保证$O(L \log L)$复杂度同时，能更好捕获依赖	由于依赖对数据季节项和趋势项分解，不适合季节性和趋势性不明显的数据
Triformer[88]	针对二次复杂度效率低问题，提出线性复杂度的三角形结构补丁注意力；针对所有变量使用相同参数问题，提出了一种轻量级方法来生成特定的变量参数	保证线性复杂度，特定于变量的投影矩阵能够有效捕捉不同时间模式，在不影响效率和内存使用情况下提高了准确性	可学习参数数量与预测前设置有关，无法动态输入预测长度
FEDformer[81]	针对计算成本高和无法捕捉全局视图问题，提出混合分解模块来控制分布偏移；提出频域增强模块和频域增强注意力，将时序数据转换到频域空间进行处理	能更好捕捉全局特性，有效利用频域信息进行表征学习以提取特征，通过随机采样，保证较好性能同时具有线性复杂度和内存占用	随机采样可能会丢失主要信息，由于在频域空间进行学习，当频率较高时，可能会导致过多冗余
Pyraformer[82]	针对长距离依赖和时间空间复杂度问题，设计一种金字塔注意力，利用树结构传递注意力信息	可以有效捕获短期和长期时间依赖性，并且具有较低时间和空间复杂度	依赖超参数选择
Non-stantionary Transformer[84]	针对过平稳化导致预测能力下降问题，提出非平稳注意力，重新纳入非平稳信息	提高数据可预测性，同时作为一个通用框架，能够有效提升其他Transformer模型预测能力	过平稳化问题不仅出现在Transformer模型中，纳入非平稳信息还有其他更加有效方法
TDformer[89]	针对不同模型在季节性、趋势性和噪声上有着不同表征能力问题，提出使用傅里叶变换和多层感知机对季节项和趋势项分别建模	针对性建模能展现出各自优势，使预测性能提高	受到序列分解限制
PatchTST[90]	针对逐点的注意力无法考虑前后信息问题，引入分割补丁技术和独立通道技术，并应用于自监督训练任务	可捕获局部语义信息，且受益于更长回顾窗口，可学习到不同注意力模式，并在自监督学习和迁移学习上有良好能力	没有分析通道间的相关性
Conformer[91]	针对稀疏注意力导致的有限信息利用限制挖掘复杂依赖关系问题，引入滑动窗口注意力和平稳瞬时循环网络模块，并用归一化流操作捕获网络中潜在状态	在保证$O(L)$复杂度同时，能有效捕捉潜在状态，并直接生成目标序列，进一步提高信息利用率，具有更高抗噪性	当时序结构化较差，难以有效捕捉其时间模式，导致性能下降
Scaleformer[86]	针对分布偏移的问题，引入一种跨尺度的归一化方法；针对迭代造成的误差累积，采用自适应损失	多尺度的迭代能够捕捉不同尺度间的依赖关系和特征，能够有效提升其他Transformer模型性能	依赖基础模型和频率变化明显的数据
Crossformer[92]	针对缺乏跨维度依赖问题，设计维度分段嵌入，提出时间、维度两阶段注意力	能捕获跨时间和跨维度依赖，并有效利用不同尺度信息以提高预测性能	在跨维度阶段，简单的全连接可能会在高维数据集上引入噪声
MTPNet[83]	针对仅在固定尺度或受约束尺度上建模无法捕获不同季节性问题，提出一种维度不变嵌入机制和多尺度金字塔结构	将数据投影到高维空间中，保留时间和变量维度，多尺度潜在表征能有效利用无约束尺度时间依赖，提高预测精度	对于低时间依赖性数据，预测性能较差
SageFormer[87]	针对序列间依赖关系难以建模问题，提出将GNN与Transformer结合，利用图结构学习不同时间模式和序列间依赖	通过全局可交互标记捕获全局信息，图聚合实现序列间信息交互，使用稀疏连接的图结构减少冗余信息	捕获到的依赖关系不具有严格因果关系，在非平稳序列中，一些依赖是不可靠的，忽略了图结构的可解释性
iTransformer[85]	针对单时间步多变量嵌入导致无法有效学习注意力图，设计了转置变量输入，利用多变量注意力和前馈神经网络分别捕获变量间和变量内相关特征	不修改任何模块情况下，将转置方法与Transformer类模型结合，能有效提升预测性能，具有很强泛化性	无法有效解决分布偏移，各种模块组件仍有改进空间
Pathformer[93]	针对有限或固定尺度难以捕捉不同尺度特征问题，提出多尺度自适应模块，集成多尺度时间分辨率和距离	实现多尺度特征综合建模，根据不同时序动态选择并聚合多尺度特征	单独傅里叶变换分解序列效果不佳，可结合MLP分别建模

中国知网 https://www.cnki.net

了分割补丁的方式，引入多尺度分割形成不同时间分辨率的视图，通过双重注意力和自适应路径动态提取多尺度特征。

4 总结与展望

4.1 总结

时间序列数据普遍存在且蕴含事物变化趋势与规律，因此时序预测任务在各个领域都有着广阔应用前景和重要作用。目前主流方法采用深度学习技术挖掘时间序列数据中蕴含的真实模式和规律，进而实现预测。但由于Transformer在时序预测领域的发展历程相对较短，现有工作在取得一定成果的同时仍存在不足。首先，模型泛化能力问题。Transformer在大规模、高质量数据上表现优异，但在小样本或噪声较多的数据集上表现较差，需要进行大量的模型调整，面对不同时序预测任务时泛化能力有限。其次，资源消耗问题。Transformer使用自注意力机制处理长序列时，高达$O(N^2)$的计算复杂度使得训练和预测过程需要大量内存和计算资源，尽管有研究工作降低了复杂度，但对于资源受限的设备或实时应用场景，进行部署并有效预测仍存在挑战。最后，模型可解释性和鲁棒性问题。Transformer模型作为黑盒模型，难以直观解释内部工作机制和决策过程。同时，针对特定应用场景的优化方法研究不足，容易受到数据影响，导致实际应用中鲁棒性存在挑战。

4.2 展望

近年来时序预测任务的研究呈现蓬勃发展态势，同时时序数据中蕴含的复杂模式和规律使得现有模型捕获数据间相关性并进行准确预测任务仍面临挑战。尽管Transformer模型在时序数据预测任务中取得了突破性成果，但仍存在很大潜力有待挖掘。为了推动时序预测任务进一步发展，下面从三个角度总结了Transformer在时序预测任务上未来可能的研究方向。

（1）Transformer与大语言模型的结合

针对模型泛化能力存在的挑战，可将Transformer与大语言模型进行结合。随着GTP、Llama等大语言模型（large language model，LLM）在NLP（natural language processing）领域蓬勃发展，TSF领域也迎来了自己的大模型，一种是使用已有大模型做时序预测，另一种是训练专属时序预测的大模型。最近研究发现，Gruver等人[94]和Jin等人[95]解决了将时序数据转化为适合LLM输入的问题，利用LLM训练时序数据并进行预测。同时Rasul等人[96]构建了用于时序任务的大模型，通过大规模预训练，在零样本情况下实现了较好性能。

但通过大规模预训练的LLM与时序预测任务的结合仍是一个挑战，目前工作并未达到最先进性能。对于TSF任务，Transformer与大语言模型结合，在实现有效零样本预测的同时，如何提升其性能仍是研究重点方向。

（2）轻量级的Transformer

针对资源消耗存在的挑战，可探索轻量级的Transformer模型用于时序预测任务。Transformer的高性能依赖于极高算力，难以实现移动端设备和实时应用场景部署。借助NLP和CV（computer vision）领域的创新，如Wu等人[97]提出了一种高效的移动端NLP架构Lite Transformer；Mehta等人[98]设计了DeLighT，其网络深度是传统Transformer的2.5倍到4倍，却有着更轻量参数；Xin等人[99]提出DeeBERT，在保证精度前提下，提高了40%预训练推理时间。因此，开发轻量级Transformer用于TSF任务是未来研究方向之一。

（3）Transformer引入归纳偏置

针对鲁棒性问题，设计合适的归纳偏置可使Transformer模型在实际应用中更加专业化，提高预测精度和鲁棒性。传统Transformer模型并不是针对时序预测任务提出的，因此没有对时间模式和特征做出任何假设，而其作为一个能够捕获长期依赖的通用网络，需要大量数据进行训练以提高泛化能力，避免过拟合。首先，趋势性和季节性是时序数据关键特征，研究表明，分解时间序列的时间模式以及转换到频域进行处理，能够有效提高预测性能[81]。此外，通过独立通道学习不同变量维度依赖[90]，以及利用两阶段注意力机制分别捕获时间维度和变量维度依赖关系同样可以得到性能改进[92]。同时，采用金字塔结构可以捕获不同时间尺度信息[82]，多尺度自适应模块也有同样效果[93]。

由于时间序列数据与图片、音频、文本等数据不同，对于TSF任务，应该基于时序数据特点和具体任务特性，对模型做出更有效调整。在Transformer中引入归纳偏置，可能会让模型学习到更有区分度的特征，使其具有更强的鲁棒性，改善Transformer模型在TSF任务上的性能，这也是一个主要研究方向。

5 结论

本文综述了基于Transformer的时序预测任务方法。随着时序数据规模不断膨胀，依靠Transformer优秀的长距离建模能力，基于Transformer的时序预测方法仍具有优势，但依然存在挑战和改进空间。

本文对近期时序数据预测任务的过程进行了调研和梳理，详细阐述了时序数据预处理、时序预测评价指标和时序数据集，从应用层面和结构层面深入分析了各

中国知网 https://www.cnki.net

种基于Transformer的时序预测模型，对比了各类模型的实验性能、改进方法、优势以及局限性，对Transformer用于时序预测任务的未来研究方向进行了探究，可为该领域的未来研究提供有价值参考。

参考文献：

[1] WEN Q S, YANG L X, ZHOU T, et al. Robust time series analysis and applications: an industrial perspective[C]//Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM, 2022: 4836-4837.

[2] ESLING P, AGON C. Time-series data mining[J]. ACM Computing Surveys, 2012, 45(1): 1-34.

[3] LIN H T, GAO Z Y, XU Y J, et al. Conditional local convolution for spatio-temporal meteorological forecasting[C]//Proceedings of the 2022 AAAI Conference on Artificial Intelligence. Menlo Park: AAAI, 2022: 7470-7478.

[4] ZHANG L, WILSON R, SUMNER M, et al. Advanced multimodal fusion method for very short-term solar irradiance forecasting using sky images and meteorological data: a gate and transformer mechanism approach[J]. Renewable Energy, 2023, 216: 118952.

[5] LU P, YE L, PEI M, et al. Short-term wind power forecasting based on meteorological feature extraction and optimization strategy[J]. Renewable Energy, 2022, 184: 642-661.

[6] WU H, LIANG Y, ZUO J Y. Human-inspired spatiotemporal feature extraction and fusion network for weather forecasting[J]. Expert Systems with Applications, 2022, 207: 118089.

[7] LAPTEV N, YOSINSKI J, LI L E, et al. Time-series extreme event forecasting with neural networks at uber[C]//Proceedings of the 34th International Conference on Machine Learning, Sydney, Aug 6-11, 2017: 1-5.

[8] LV Y S, DUAN Y J, KANG W W, et al. Traffic flow prediction with big data: a deep learning approach[J]. IEEE Transactions on Intelligent Transportation Systems, 2014, 16(2): 865-873.

[9] LI Y G, YU R, SHABABI C, et al. Diffusion convolutional recurrent neural network: data-driven traffic forecasting[C]//Proceedings of the 35th International Conference on Machine Learning, Stockholmsmässan, Jul 10-15, 2018.

[10] SHAO H, SOONG B H. Traffic flow prediction with long short-term memory networks (LSTMs)[C]//Proceedings of the 2016 IEEE Region 10 Conference. Piscataway: IEEE, 2016: 2986-2989.

[11] 王永恒, 高慧, 陈炫伶. 采用变结构动态贝叶斯网络的交通流量预测[J]. 计算机科学与探索, 2017, 11(4): 528-538.
WANG Y H, GAO H, CHEN X L. Traffic prediction method using structure varying dynamic Bayesian networks [J]. Journal of Frontiers of Computer Science and Technology, 2017, 11(4): 528-538.

[12] ROJO-ALVAREZ J L, MARTINEZ-RAMON M, DE PRADO-CUMPLIDO M, et al. Support vector method for robust ARMA system identification[J]. IEEE Transactions on Signal Processing, 2004, 52(1): 155-164.

[13] CALLOT L A F, KOCK A B, MEDEIROS M C. Modeling and forecasting large realized covariance matrices and portfolio choice[J]. Journal of Applied Econometrics, 2017, 32 (1): 140-158.

[14] CALLOT L, CANER M, ONDER A O, et al. A nodewise regression approach to estimating large portfolios[J]. Journal of Business & Economic Statistics, 2021, 39(2): 520-531.

[15] LUO R, ZHANG W N, XU X J, et al. A neural stochastic volatility model[C]//Proceedings of the 32nd AAAI Conference on Artificial Intelligence, the 30th Innovative Applications of Artificial Intelligence, and the 8th AAAI Symposium on Educational Advances in Artificial Intelligence. Menlo Park: AAAI, 2018: 6401-6408.

[16] BALLESTRA L V, GUIZZARDI A, PALLADINI F. Forecasting and trading on the VIX futures market: a neural network approach based on open to close returns and coincident indicators[J]. International Journal of Forecasting, 2019, 35(4): 1250-1262.

[17] YAN X, ZHANG W Z, MA L, et al. Parsimonious quantile regression of financial asset tail dynamics via sequential learning[C]//Advances in Neural Information Processing Systems 31, Montréal, Dec 3-8, 2018: 1582-1592.

[18] 赵洪科, 吴李康, 李徵, 等. 基于深度神经网络结构的互联网金融市场动态预测[J]. 计算机研究与发展, 2019, 56(8): 1621-1631.
ZHAO H K, WU L K, LI Z, et al. Predicting the dynamics in internet finance based on deep neural network structure [J]. Journal of Computer Research and Development, 2019, 56(8): 1621-1631.

[19] LUKSZA M, LASSIG M. A predictive fitness model for influenza[J]. Nature, 2014, 507(7490): 57-61.

[20] BOYLE J R, SPARKS R S, KEIJZERS G B, et al. Prediction and surveillance of influenza epidemics[J]. Medical Journal of Australia, 2011, 194: S28-S33.

[21] BORKENHAGEN L K, ALLEN M W, RUNSTADLER J A. Influenza virus genotype to phenotype predictions through machine learning: a systematic review: computational prediction of influenza phenotype[J]. Emerging Microbes & Infections, 2021, 10(1): 1896-1907.

[22] LEE E K, TIAN H, NAKAYA H I. Antigenicity prediction and vaccine recommendation of human influenza virus A (H3N2) using convolutional neural networks[J]. Human Vaccines & Immunotherapeutics, 2020, 16(11): 2690-2708.

[23] ZHAO H C, ZHANG X Y, ZHAO Q C, et al. MSDRP: a deep learning model based on multisource data for predicting drug response[J]. Bioinformatics, 2023, 39(9): btad514.

[24] GERDES H, CASADO P, DOKAL A, et al. Drug ranking using machine learning systematically predicts the efficacy of anti-cancer drugs[J]. Nature Communications, 2021, 12 (1): 1850.

中国知网 https://www.cnki.net

[25] LYU T, GAO J L, TIAN L, et al. MDNN: a multimodal deep neural network for predicting drug-drug interaction events[C]//Proceedings of the 30th International Joint Conference on Artificial Intelligence, Aug 19-27, 2021: 3536-3542.
[26] DIMOULKAS I, MAZIDI P, HERRE L. Neural networks for GEFCom2017 probabilistic load forecasting[J]. International Journal of Forecasting, 2019, 35(4): 1409-1423.
[27] SAXENA H, APONTE O, MCCONKY K T. A hybrid machine learning model for forecasting a billing period's peak electric load days[J]. International Journal of Forecasting, 2019, 35(4): 1288-1303.
[28] SMYL S, HUA N G. Machine learning methods for GEFCom2017 probabilistic load forecasting[J]. International Journal of Forecasting, 2019, 35(4): 1424-1431.
[29] GERS F A, SCHMIDHUBER J, CUMMINS F. Learning to forget: continual prediction with LSTM[J]. Neural computation, 2000, 12(10): 2451-2471.
[30] PASCANU R, MIKOLOV T, BENGIO Y. On the difficulty of training recurrent neural networks[C]//Proceedings of the 30th International Conference on Machine Learning, Atlanta, Jun 16-21, 2013: 1310-1318.
[31] CHO K, VAN MERRIENBOER B, GULCEHRE C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[C]//Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2014: 1724-1734.
[32] DURBIN J, KOOPMAN S J. Time series analysis by state space methods[M]. 2nd ed. Oxford: Oxford University Press, 2012.
[33] 康梦轩, 宋俊平, 范鹏飞, 等. 基于深度学习的网络流量预测研究综述[J]. 计算机工程与应用, 2021, 57(10): 1-9.
KANG M X, SONG J P, FAN P F, et al. Survey of network traffic forecast based on deep learning[J]. Computer Engineering and Applications, 2021, 57(10): 1-9.
[34] ELMAN J L. Finding structure in time[J]. Cognitive Science, 1990, 14(2): 179-211.
[35] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. Neural Computation, 1997, 9(8): 1735-1780.
[36] CHUNG J Y, GULCEHRE C, CHO K, et al. Empirical evaluation of gated recurrent neural networks on sequence modeling[EB/OL]. [2024-01-14]. https://arxiv.org/abs/1412.3555.
[37] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 1998, 86(11): 2278-2324.
[38] ROSENBLATT F. The Perceptron: a probabilistic model for information storage and organization in the brain[J]. Psychological Review, 1958, 65(6): 386.
[39] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[C]//Advances in Neural Information Processing Systems 30, Long Beach, Dec 4-9, 2017: 5998-6008.
[40] WEN Q S, ZHOU T, ZHANG C L, et al. Transformers in time series: a survey[C]//Proceedings of the 32nd International Joint Conference on Artificial Intelligence, Macao, China, Aug 19-25, 2023: 6778-6786.
[41] 梁宏涛, 刘硕, 杜军威, 等. 深度学习应用于时序预测研究综述[J]. 计算机科学与探索, 2023, 17(6): 1285-1300.
LIANG H T, LIU S, DU J W, et al. Review of deep learning applied to time series prediction[J]. Journal of Frontiers of Computer Science and Technology, 2023, 17(6): 1285-1300.
[42] RAMIREZ-GALLEGO S, KRAWCZYK B, GARCIA S, et al. A survey on data preprocessing for data stream mining: current status and future directions[J]. Neurocomputing, 2017, 239: 39-57.
[43] KOTSIANTIS S B, KANELLOPOULOS D, PINTELAS P E. Data preprocessing for supervised leaning[J]. International Journal of Computer Science, 2006, 1(2): 111-117.
[44] 刘明吉, 王秀峰, 黄亚楼. 数据挖掘中的数据预处理[J]. 计算机科学, 2000, 27(4): 54-57.
LIU M J, WANG X F, HUANG Y L. Data preprocessing in data mining[J]. Computer Science, 2000, 27(4): 54-57.
[45] GARCIA S, RAMIREZ-GALLEGO S, LUENGO J, et al. Big data preprocessing: methods and prospects[J]. Big Data Analytics, 2016, 1(1): 1-22.
[46] TAM S, TSAO M S, MCPHERSON J D. Optimization of miRNA-seq data preprocessing[J]. Briefings in Bioinformatics, 2015, 16(6): 950-963.
[47] BILAL M, ALI G, IQBAL M W, et al. Auto-prep: efficient and automated data preprocessing pipeline[J]. IEEE Access, 2022, 10: 107764-107784.
[48] HU F, LAKDAWALA S, HAO Q, et al. Low-power, intelligent sensor hardware interface for medical data preprocessing[J]. IEEE Transactions on Information Technology in Biomedicine, 2009, 13(4): 656-663.
[49] HURTIK P, MOLEK V, HULA J. Data preprocessing technique for neural networks based on image represented by a fuzzy function[J]. IEEE Transactions on Fuzzy Systems, 2019, 28(7): 1195-1204.
[50] SRIVASTAVA S. Weka: a tool for data preprocessing, classification, ensemble, clustering and association rule mining [J]. International Journal of Computer Applications, 2014, 88(10).
[51] HUANG M W, LIN W C, CHEN C W, et al. Data preprocessing issues for incomplete medical datasets[J]. Expert Systems, 2016, 33(5): 432-438.
[52] DASU T, JOHNSON T. Exploratory data mining and data cleaning[M]. Hoboken: John Wiley & Sons, 2003.
[53] 曹勇, 于海. 基于重要度计算的物联网时序大数据智能清洗算法[J]. 自动化与仪器仪表, 2023(12): 71-75.
CAO Y, YU H. Intelligent data cleaning algorithm for IoT time series big data based on importance calculation[J]. Automation & Instrumentation, 2023(12): 71-75.
[54] 韩京宇, 陈伟, 赵静, 等. 基于异常特征模式的心电数据标

中国知网 https://www.cnki.net

签清洗方法[J]. 计算机研究与发展, 2023, 60(11): 2594-2610.
HAN J Y, CHEN W, ZHAO J, et al. A label cleaning method of ECG data based on abnormality-feature patterns [J]. Journal of Computer Research and Development, 2023, 60(11): 2594-2610.
[55] KIRCHNER K, ZEC J, DELIBASIC B. Facilitating data preprocessing by a generic framework: a proposal for clustering[J]. Artificial Intelligence Review, 2016, 45: 271-297.
[56] SATHYANARAYANAN A, MUELLER T T, MONI M A, et al. Multi-omics data integration methods and their applications in psychiatric disorders[J]. European Neuropsychopharmacology, 2023, 69: 26-46.
[57] ZHENG Y T, LIU Y Q, YANG J C, et al. Multi-omics data integration using ratio-based quantitative profiling with Quartet reference materials[J]. Nature Biotechnology, 2024, 42: 1133-1149.
[58] 陈超, 胡才亮, 崔钰, 等. 基于时空聚类的多源异构时序数据集成方法[J]. 电子设计工程, 2023, 31(20): 168-171.
CHEN C, HU C L, CUI Y, et al. Multi-source heterogeneous time series data integration method based on spatiotemporal clustering[J]. Electronic Design Engineering, 2023, 31(20): 168-171.
[59] MARKERT K N, WILLIAMS G P, NELSON E J, et al. Dense time series generation of surface water extents through optical-SAR sensor fusion and gap filling[J]. Remote Sensing, 2024, 16(7): 1262.
[60] KARIMVAND S K, JAFARI J M, ZADE S V, et al. Practical and comparative application of efficient data reduction-multivariate curve resolution[J]. Analytica Chimica Acta, 2023, 1243: 340824.
[61] ESCHRICH S, KE J W, HALL L O, et al. Fast accurate fuzzy clustering through data reduction[J]. IEEE Transactions on Fuzzy Systems, 2003, 11(2): 262-270.
[62] 崔振, 任亚洲, 王瑞. 基于DCT的时序数据相似性搜索[J]. 计算机应用, 2007(5): 1232-1234.
CUI Z, REN Y Z, WANG R. Similarity search over time series data using DCT[J]. Journal of Computer Applications, 2007(5): 1232-1234.
[63] 刘洪波, 盖雪扬, 孙黎, 等. 计及数据降维和数据清洗的超短期风电功率预测[J]. 东北电力大学学报, 2023, 43(4): 1-9.
LIU H B, GAI X Y, SUN L, et al. Ultra-short-term wind power prediction considering data reduction and data cleaning[J]. Journal of Northeast Electric Power University, 2023, 43(4): 1-9.
[64] KESTER W. Data conversion handbook[M]. Newnes, 2005.
[65] OGASAWARA E, MARTINEZ L C, DE OLIVEIRA D, et al. Adaptive normalization: a novel data normalization approach for non-stationary time series[C]//Proceedings of the 2010 International Joint Conference on Neural Networks. Piscataway: IEEE, 2010: 1-8.
[66] WANG Z, BOVIK A C. Mean squared error: love it or leave it? A new look at signal fidelity measures[J]. IEEE Signal Processing Magazine, 2009, 26(1): 98-117.
[67] HODSON T O. Root mean square error (RMSE) or mean absolute error (MAE): when to use or not[J]. Geoscientific Model Development, 2014, 7(3): 1247-1250.
[68] WILLMOTT C J, MATSUURA K. Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance[J]. Climate Research, 2005, 30(1): 79-82.
[69] DE MYTTENAERE A, GOLDEN B, LE GRAND B, et al. Mean absolute percentage error for regression models[J]. Neurocomputing, 2016, 192: 38-48.
[70] HABYARIMANA J B. Forecasting crop production: a seasonal regression model decomposition of MAPE and SMAPE[J]. Journal of Statistical Science and Application, 2014, 2: 203-212.
[71] CAMERON A C, WINDMEIJER F A G. An R-squared measure of goodness of fit for some common nonlinear regression models[J]. Journal of Econometrics, 1997, 77(2): 329-342.
[72] CHICCO D, WARRENS M J, JURMAN G. The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation[J]. PeerJ Computer Science, 2021, 7: e623.
[73] CHOROWSKI J K, BAHDANAU D, SERDYUK D, et al. Attention-based models for speech recognition[C]//Advances in Neural Information Processing Systems 28, Montreal, Dec 7-12, 2015: 577-585.
[74] BAHDANAU D, CHO K, BENGIO Y. Neural machine translation by jointly learning to align and translate[C]//Proceedings of the 3rd International Conference on Learning Representations, San Diego, May 7-9, 2015.
[75] SONG H, RAJAN D, THIAGARAJAN J, et al. Attend and diagnose: clinical time series analysis using attention models[C]//Proceedings of the 2018 AAAI Conference on Artificial Intelligence. Menlo Park: AAAI, 2018: 4091-4098.
[76] JIN K H, WI J A, LEE E J, et al. TrafficBERT: pre-trained model with large-scale data for long-range traffic flow forecasting[J]. Expert Systems with Applications, 2021, 186: 115738.
[77] ZERVEAS G, JAYARAMAN S, PATEL D, et al. A transformer-based framework for multivariate time series representation learning[C]//Proceedings of the 27th ACM SIGKDD Conference on Knowledge Discovery and Data Mining. New York: ACM, 2021: 2114-2124.
[78] LI S Y, JIN X Y, XUAN Y, et al. Enhancing the locality and breaking the memory bottleneck of transformer on time series forecasting[C]//Advances in Neural Information Processing Systems 32, Vancouver, Dec 8-14, 2019: 5244-5254.
[79] ZHOU H Y, ZHANG S H, PENG J Q, et al. Informer: beyond efficient transformer for long sequence time-series forecasting[C]//Proceedings of the 2021 AAAI conference

中国知网 https://www.cnki.net

on Artificial Intelligence. Menlo Park: AAAI, 2021: 11106-11115.

[80] WU H X, XU J H, WANG J M, et al. Autoformer: decomposition transformers with auto-correlation for long-term series forecasting[C]//Advances in Neural Information Processing Systems 34, Dec 6-14, 2021: 22419-22430.

[81] ZHOU T, MA Z Q, WEN Q S, et al. Fedformer: frequency enhanced decomposed transformer for long-term series forecasting[C]//Proceedings of the 39th International Conference on Machine Learning, Baltimore, Jul 17-23, 2022: 27268-27286.

[82] LIU S Z, YU H, LIAO C, et al. Pyraformer: low-complexity pyramidal attention for long-range time series modeling and forecasting[C]//Proceedings of the 10th International Conference on Learning Representations, Apr 25-29, 2022.

[83] ZHANG Y F, WU R, DASCALU S M, et al. Multi-scale transformer pyramid networks for multivariate time series forecasting[J]. IEEE Access, 2024, 12: 14731-14741.

[84] LIU Y, WU H X, WANG J M, et al. Non-stationary transformers: exploring the stationarity in time series forecasting [C]//Advances in Neural Information Processing Systems 35, New Orleans, Nov 28-Dec 9, 2022: 9881-9893.

[85] LIU Y, HU T, ZHANG H, et al. iTransformer: inverted transformers are effective for time series forecasting[C]// Proceedings of the 12th International Conference on Learning Representations, Vienna, May 7-11, 2024.

[86] SHABANI A, ABDI A, MENG L L, et al. Scaleformer: iterative multi-scale refining transformers for time series forecasting[C]//Proceedings of the 11th International Conference on Learning Representations, Kigali, May 1-5, 2023.

[87] ZHANG Z W, MENG L H, GU Y T. SageFormer: series-aware framework for long-term multivariate time series forecasting[J]. IEEE Internet of Things Journal, 2024, 11 (10): 18435-18448.

[88] CIRSTEA R G, GUO C J, YANG B, et al. Triformer: triangular variable-specific attentions for long sequence multivariate time series forecasting[C]//Proceedings of the 31st International Joint Conference on Artificial Intelligence, Vienna, Jul 23-29, 2022: 1994-2001.

[89] ZHANG X Y, JIN X Y, GOPALSWAMY K, et al. First detrend then attend: rethinking attention for time-series forecasting[EB/OL]. [2024-01-14]. https://arxiv.org/abs/2212.08151.

[90] NIE Y Q, NGUYEN N H, SINTHONG P, et al. A time series is worth 64 words: long-term forecasting with transformers[C]//Proceedings of the 11th International Conference on Learning Representations, Kigali, May 1-5, 2023.

[91] LI Y, LU X J, XIONG H Y, et al. Towards long-term time-series forecasting: feature, pattern, and distribution[C]//Proceedings of the 39th IEEE International Conference on Data Engineering. Piscataway: IEEE, 2023: 1611-1624.

[92] ZHANG Y H, YAN J C. Crossformer: transformer utilizing cross-dimension dependency for multivariate time series forecasting[C]//Proceedings of the 11th International Conference on Learning Representations, Kigali, May 1-5, 2023.

[93] CHEN P, ZHANG Y Y, CHENG Y Y, et al. Pathformer: multi-scale transformers with adaptive pathways for time series forecasting[C]//Proceedings of the 12th International Conference on Learning Representations, Vienna, May 7-11, 2024.

[94] GRUVER N, FINZI M, QIU S K, et al. Large language models are zero-shot time series forecasters[C]//Advances in Neural Information Processing Systems 36, New Orleans, Dec 10-16, 2023.

[95] JIN M, WANG S Y, MA L T, et al. Time-LLM: time series forecasting by reprogramming large language models[C]// Proceedings of the 12th International Conference on Learning Representations, Vienna, May 7-11, 2024.

[96] RASUL K, ASHOK A, WILLIAMS A R, et al. Lag-Llama: towards foundation models for time series forecasting[C]// Advances in Neural Information Processing Systems 36, New Orleans, Dec 10-16, 2023.

[97] WU Z H, LIU Z J, LIN J, et al. Lite Transformer with long-short range attention[C]//Proceedings of the 8th International Conference on Learning Representations, Addis Ababa, Apr 26-30, 2020.

[98] MEHTA S, GHAZVININEJAD M, IYER S, et al. DeLighT: deep and light-weight transformer[C]//Proceedings of the 9th International Conference on Learning Representations, Austria, May 3-7, 2021.

[99] XIN J, TANG R, LEE J, et al. DeeBERT: dynamic early exiting for accelerating BERT inference[C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2020: 2246-2251.

孟祥福(1981—),男,辽宁朝阳人,博士,教授,博士生导师,CCF会员,主要研究方向为空间数据管理、兴趣点推荐系统、Web数据库查询、时序数据库系统。

MENG Xiangfu, born in 1981, Ph.D., professor, Ph.D. supervisor, CCF member. His research interests include spatial data management, point of interest recommender system, Web database query and time series database system.

石皓源(1999—),男,辽宁抚顺人,硕士研究生,主要研究方向为时序数据预测、异常检测。

SHI Haoyuan, born in 1999, M.S. candidate. His research interests include time series forecasting and anomaly detection.

中国知网 https://www.cnki.net